



Сводная таблица вариантов

№	Предметная область	Задача (кратко)	Парадигмы ИИ
1	Медицинская диагностика	Построить систему поддержки принятия решений для предварительной диагностики з...	· Продукционные правила · Онтология · Граф знаний
2	Городской общественный транспорт	Разработать систему анализа и прогнозирования задержек городского транспорта д...	· Продукционные правила · Агентная модель · Генетический алгоритм
3	Кредитный скоринг	Создать экспертную систему оценки кредитоспособности заёмщика на основе финанс...	· Продукционные правила · Фреймы · Логика (Prolog)
4	Мониторинг качества воздуха	Построить систему мониторинга и классификации уровня загрязнения воздуха в гор...	· Продукционные правила · Онтология · Агентная модель
5	Система управления обучением (LMS)	Разработать систему персонализированных рекомендаций учебных материалов для ст...	· Продукционные правила · Граф знаний · Фреймы
6	Интернет-торговля (e-commerce)	Построить систему персонализированных товарных рекомендаций и сегментации поку...	· Продукционные правила · Семантическая сеть · Генетический алгоритм
7	Агромониторинг и точное земледелие	Создать систему мониторинга состояния посевов и рекомендаций по агротехнически...	· Продукционные правила · Онтология · Генетический алгоритм
8	Энергопотребление и умный дом	Построить систему анализа и оптимизации энергопотребления в зданиях с выявлени...	· Продукционные правила · Фреймы · Агентная модель
9	Новостная аналитика и медиамониторинг	Разработать систему автоматической рубрикации новостных статей и обнаружения т...	· Продукционные правила · Семантическая сеть · Граф знаний
10	Промышленное оборудование и предиктивное обслуживание	Создать систему предсказания отказов оборудования для планирования профилактич...	· Продукционные правила · Фреймы · Генетический алгоритм
11	Умный город: безопасность и преступность	Построить систему анализа криминогенной обстановки и прогнозирования зон повыш...	· Продукционные правила · Граф знаний · Агентная модель
12	Туризм и персонализация путешествий	Разработать систему рекомендаций туристических маршрутов и достопримечательнос...	· Фреймы · Семантическая сеть · Генетический алгоритм
13	HR-аналитика и управление персоналом	Создать систему прогнозирования увольнений сотрудников и рекомендаций по удерж...	· Продукционные правила · Фреймы · Логика (Prolog)
14	Спортивная аналитика	Построить систему анализа статистики команд и прогнозирования результатов футб...	· Продукционные правила · Семантическая сеть · Генетический алгоритм
15	Телекоммуникации и анализ оттока клиентов	Разработать систему раннего выявления клиентов, склонных к смене оператора свя...	· Продукционные правила · Фреймы · Логика (Prolog)

№	Предметная область	Задача (кратко)	Парадигмы ИИ
16	Цифровые библиотеки и архивы	Создать интеллектуальную систему каталогизации и тематического поиска в коллек...	· Онтология · Граф знаний · Семантическая сеть
17	Страхование и оценка рисков	Построить экспертную систему оценки страховых рисков и выявления мошеннических...	· Продукционные правила · Фреймы · Логика (Prolog)
18	Водоснабжение и качество воды	Разработать систему мониторинга качества питьевой воды и прогнозирования наруш...	· Продукционные правила · Онтология · Агентная модель
19	Недвижимость и оценка объектов	Создать систему оценки рыночной стоимости жилой недвижимости и анализа инвести...	· Продукционные правила · Фреймы · Генетический алгоритм
20	Фармацевтика и лекарственные взаимодействия	Построить систему проверки совместимости лекарственных препаратов и поддержки ...	· Онтология · Продукционные правила · Граф знаний
21	Логистика и управление цепочками поставок	Разработать систему оптимизации маршрутов доставки и управления складскими зап...	· Продукционные правила · Агентная модель · Генетический алгоритм
22	Кибербезопасность и обнаружение вторжений	Создать систему обнаружения аномалий в сетевом трафике и классификации типов к...	· Продукционные правила · Граф знаний · Агентная модель
23	Образование: анализ успеваемости школьников	Построить систему раннего выявления учеников, нуждающихся в дополнительной под...	· Продукционные правила · Фреймы · Логика (Prolog)
24	Переработка отходов и экология города	Разработать систему классификации и маршрутизации твёрдых бытовых отходов для ...	· Продукционные правила · Онтология · Агентная модель
25	Ресторанный бизнес и гастрономия	Создать систему анализа отзывов посетителей и рекомендаций по улучшению меню и...	· Продукционные правила · Семантическая сеть · Граф знаний
26	Авиация и безопасность полётов	Построить экспертную систему анализа инцидентов и оценки рисков при выполнении...	· Продукционные правила · Онтология · Логика (Prolog)
27	Банковское дело и анализ транзакций	Разработать систему обнаружения мошеннических транзакций в реальном времени.	· Продукционные правила · Фреймы · Агентная модель
28	Климат и метеорология	Создать систему анализа климатических данных и прогнозирования экстремальных п...	· Продукционные правила · Онтология · Генетический алгоритм
29	Игровая индустрия и геймдизайн	Построить систему анализа поведения игроков и динамической адаптации сложности...	· Продукционные правила · Фреймы · Агентная модель
30	Социальные сети и анализ сообществ	Разработать систему выявления тематических сообществ и ключевых узлов влияния ...	· Граф знаний · Семантическая сеть · Генетический алгоритм
31	Умное сельское хозяйство и теплицы	Разработать систему управления микроклиматом теплицы с автоматическим регулированием темпе...	· Продукционные правила · Фреймы · Агентная модель
32	Юридическая экспертиза и анализ договоров	Построить экспертную систему для автоматического анализа типовых гражданско-правовых догов...	· Продукционные правила · Онтология · Логика (Prolog)

№	Предметная область	Задача (кратко)	Парадигмы ИИ
33	Оценка качества программного обеспечения	Создать систему автоматической оценки качества программного кода: выявление дефектов, анти...	• Продукционные правила • Граф знаний • Фреймы
34	Рекомендательная система для кино и стриминга	Разработать гибридную рекомендательную систему для стримингового сервиса с учётом контента...	• Семантическая сеть • Граф знаний • Продукционные правила
35	Анализ дорожно-транспортных происшествий	Построить систему анализа причин дорожно-транспортных происшествий и прогнозирования опасн...	• Продукционные правила • Онтология • Генетический алгоритм
36	Управление складом и инвентаризация	Создать интеллектуальную систему управления складскими запасами: прогнозирование потребнос...	• Продукционные правила • Фреймы • Генетический алгоритм
37	Диагностика и обслуживание автомобилей	Разработать экспертную систему диагностики неисправностей автомобилей по OBD-кодам, симпто...	• Продукционные правила • Онтология • Фреймы
38	Управление проектами и оценка рисков	Построить систему интеллектуальной поддержки управления IT-проектами: оценка рисков срыва ...	• Продукционные правила • Фреймы • Логика (Prolog)
39	Умный дом и интернет вещей	Создать систему управления умным домом с автоматизацией сценариев, обнаружением аномалий в...	• Продукционные правила • Агентная модель • Фреймы
40	Анализ научных публикаций и цитирований	Разработать систему интеллектуального поиска и анализа научных публикаций: выявление тренд...	• Онтология • Граф знаний • Семантическая сеть
41	Анализ текста и классификация отзывов	Построить систему интеллектуального анализа отзывов клиентов: тематическая классификация, ...	• Семантическая сеть • Продукционные правила • Онтология
42	Геоинформационный анализ и планирование территорий	Разработать систему анализа территориального планирования: оценка пригодности земельных уч...	• Продукционные правила • Онтология • Генетический алгоритм
43	Управление качеством питания и диетология	Создать интеллектуальную систему персонализированных диетических рекомендаций с учётом сос...	• Продукционные правила • Онтология • Семантическая сеть
44	Биржевая торговля и портфельный анализ	Построить систему анализа фондового рынка: формирование инвестиционного портфеля, оценка р...	• Продукционные правила • Фреймы • Генетический алгоритм
45	Персонализация новостной ленты	Разработать систему персонализации новостной ленты: профилирование интересов пользователя,...	• Семантическая сеть • Граф знаний • Агентная модель
46	Контроль и аудит цепочки производства продуктов	Создать систему прослеживаемости и аудита продовольственной цепочки: отслеживание происхож...	• Продукционные правила • Онтология • Граф знаний
47	Поддержка пациентов с хроническими заболеваниями	Построить систему мониторинга и поддержки пациентов с хроническими заболеваниями (диабет, ...	• Продукционные правила • Фреймы • Агентная модель

№	Предметная область	Задача (кратко)	Парадигмы ИИ
48	Речной и морской транспорт	Разработать систему оптимизации маршрутов водного транспорта с учётом погодных условий, гр...	• Продукционные правила • Агентная модель • Генетический алгоритм
49	Педагогическая диагностика и адаптивное обучение	Создать систему адаптивного тестирования и диагностики пробелов в знаниях студентов: постр...	• Продукционные правила • Фреймы • Граф знаний
50	Управление дорожной инфраструктурой	Построить систему интеллектуального управления дорожным движением: адаптивная работа свето...	• Продукционные правила • Агентная модель • Онтология
51	Выявление плагиата и академической нечестности	Разработать систему обнаружения плагиата в студенческих работах и академических публикация...	• Семантическая сеть • Продукционные правила • Граф знаний
52	Анализ дефектов в производстве электроники	Создать систему контроля качества производства электронных компонентов: классификация типо...	• Продукционные правила • Фреймы • Генетический алгоритм
53	Система ответов на вопросы и чат-поддержка	Построить интеллектуальную систему ответов на вопросы пользователей в предметной области т...	• Семантическая сеть • Граф знаний • Продукционные правила
54	Пожарная безопасность и предотвращение возгораний	Разработать систему раннего прогнозирования и мониторинга пожарной опасности: оценка риска...	• Продукционные правила • Онтология • Агентная модель
55	Анализ финансовой отчётности компаний	Создать экспертную систему для анализа финансовой отчётности предприятий: оценка платёжесп...	• Продукционные правила • Онтология • Логика (Prolog)
56	Управление отходами и раздельный сбор мусора	Построить систему оптимизации раздельного сбора и маршрутизации вывоза бытовых отходов в г...	• Продукционные правила • Агентная модель • Генетический алгоритм
57	Анализ биомедицинских данных и клинических исследований	Разработать систему поддержки клинических исследований: структурирование данных пациентов,...	• Онтология • Граф знаний • Продукционные правила
58	Онлайн-образование и МООС-платформы	Создать систему прогнозирования успешности прохождения онлайн-курсов и снижения оттока: вы...	• Продукционные правила • Фреймы • Логика (Prolog)
59	Туристическая индустрия и бронирование отелей	Построить систему управления доходностью отеля: прогнозирование спроса, динамическое ценоо...	• Продукционные правила • Фреймы • Генетический алгоритм
60	Мониторинг шума и акустическая экология города	Разработать систему мониторинга и классификации источников городского шума: картирование а...	• Продукционные правила • Онтология • Граф знаний

Подробные карточки вариантов практических заданий

Каждая карточка задаёт один вариант практического задания: формулировку задачи, рекомендуемые парадигмы искусственного интеллекта для её решения и таблицу источников данных с прямыми ссылками. Парадигмы выделены цветом по типу — расшифровка цветов приведена ниже.

Продукционные правила	Семантическая сеть	Онтология	Граф знаний
Фреймы	Логика (Prolog)	Агентная модель	Генетический алгоритм

Цветовые обозначения парадигм ИИ, используемые в карточках.

Вариант 1. Медицинская диагностика

Задача. Построить систему поддержки принятия решений для предварительной диагностики заболеваний по симптомам пациента.

Данные. Kaggle: Disease Symptom Prediction Dataset; UCI: Heart Disease

Парадигмы:

Продукционные правила База диагностических правил ЕСЛИ симптом → ТОГДА диагноз	Онтология Иерархия болезней, симптомов и органов тела	Граф знаний Связи: симптом — болезнь — лечение — препарат
---	--	--

Вариант 1. Медицинская диагностика				
№	Название датасета	Описание	Формат	Лицензия
1	Disease Symptom Prediction Dataset https://www.kaggle.com/datasets/itachi9604/disease-symptom-description-dataset	41 болезнь, 132 симптома. Идеально для продукционных правил диагностики.	CSV	CC0
2	Heart Disease UCI https://archive.ics.uci.edu/dataset/45/heart+disease	303 пациента, 14 клинических признаков. Классический датасет для классификации.	CSV	CC BY
3	Pima Indians Diabetes https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database	768 записей, 8 признаков. Диагностика диабета у женщин.	CSV	CC0
4	Medical Information Mart (MIMIC-III) https://physionet.org/content/mimiciii/1.4/	Реальные данные пациентов отделения интенсивной терапии. Требуется регистрация.	CSV/SQL	Research

Таблица 1. Рекомендуемые источники данных — вариант 1. Медицинская диагностика

Вариант 2. Городской общественный транспорт

Задача. Разработать систему анализа и прогнозирования задержек городского транспорта для оптимизации расписания.

Данные. Open Data: GTFS-датасеты городов; Kaggle: NYC Transit Data

Парадигмы:

Продукционные правила Правила предупреждения диспетчера при критических задержках	Агентная модель Агенты-транспортные средства, взаимодействующие с агентом-диспетчером	Генетический алгоритм Оптимизация расписания движения по остановкам
---	---	---

Вариант 2. Городской общественный транспорт				
№	Название датасета	Описание	Формат	Лицензия
1	NYC MTA Transit Data (GTFS) https://new.mta.info/developers	Расписания, маршруты, задержки автобусов и метро Нью-Йорка.	GTFS/CSV	Open
2	Chicago Transit Authority Open Data https://data.cityofchicago.org/Transportation/CTA-Ridership-Daily-Board-Totals/6iiy-9s97	Ежедневная посадка пассажиров с 2001 года по всем линиям.	CSV	Public Domain
3	Kaggle: NYC Yellow Taxi Trip Records https://www.kaggle.com/datasets/elemento/nyc-yellow-taxi-trip-data	Миллионы поездок с координатами, временем, стоимостью.	CSV	CC0
4	Transport for London Open Data https://tfl.gov.uk/info-for/open-data-users/	Данные лондонского транспорта: метро, автобусы, велосипеды.	JSON/CSV	Open

Таблица 2. Рекомендуемые источники данных — вариант 2. Городской общественный транспорт

Вариант 3. Кредитный скоринг

Задача. Создать экспертную систему оценки кредитоспособности заёмщика на основе финансовых показателей и кредитной истории.

Данные. Kaggle: Give Me Some Credit; UCI: German Credit Data

Парадигмы:

Продукционные правила Правила оценки риска: доход, долговая нагрузка, история	Фреймы Фрейм профиля заёмщика со слотами: доход, обязательства, история	Логика (Prolog) Логический вывод решения о выдаче кредита
---	---	---

Вариант 3. Кредитный скоринг				
№	Название датасета	Описание	Формат	Лицензия
1	Give Me Some Credit (Kaggle) https://www.kaggle.com/c/GiveMeSomeCredit/data	150 000 записей с признаками заёмщиков и меткой дефолта. Соревновательный датасет.	CSV	CC0
2	German Credit Data (UCI) https://archive.ics.uci.edu/dataset/144/statlog+german+credit+data	1000 клиентов, 20 признаков (возраст, статус, цель кредита). Классика.	CSV	CC BY

3	Home Credit Default Risk https://www.kaggle.com/c/home-credit-default-risk/data	Большой датасет с историей займов, платежей, демографией.	CSV	CC0
4	Lending Club Loan Data https://www.kaggle.com/datasets/wordsforthewise/lending-club	Реальные данные P2P-кредитования: параметры займа + статус погашения.	CSV	CC0

Таблица 3. Рекомендуемые источники данных — вариант 3. Кредитный скоринг

Вариант 4. Мониторинг качества воздуха

Задача. Построить систему мониторинга и классификации уровня загрязнения воздуха в городах с рекомендациями для населения.

Данные. UCI: Air Quality Dataset; Kaggle: Air Pollution in Seoul; OpenAQ API

Парадигмы:

Продукционные правила Правила классификации AQI и генерации рекомендаций	Онтология Онтология загрязнителей, источников выброса и рисков здоровью	Агентная модель Агенты-датчики, передающие данные агенту-аналитику
--	---	--

Вариант 4. Мониторинг качества воздуха				
№	Название датасета	Описание	Формат	Лицензия
1	Air Quality UCI Dataset https://archive.ics.uci.edu/dataset/360/air+quality	Почасовые измерения CO, NOx, NO2, O3 в итальянском городе. 9358 записей.	CSV	CC BY
2	Air Pollution in Seoul (Kaggle) https://www.kaggle.com/datasets/bappekim/air-pollution-in-seoul	Ежечасные данные по 25 районам Сеула: SO2, NO2, CO, O3, PM2.5, PM10.	CSV	CC0
3	OpenAQ API https://openaq.org/developers/	Открытый API с реальными данными тысяч станций мониторинга по всему миру.	JSON/API	CC BY
4	WHO Ambient Air Quality Database https://www.who.int/data/gho/data/themes/air-pollution	Глобальные данные ВОЗ о качестве воздуха в 6000+ городов.	CSV/Excel	Open

Таблица 4. Рекомендуемые источники данных — вариант 4. Мониторинг качества воздуха

Вариант 5. Система управления обучением (LMS)

Задача. Разработать систему персонализированных рекомендаций учебных материалов для студентов на основе их успеваемости и поведения.

Данные. Kaggle: Open University Learning Analytics; EDM datasets

Парадигмы:

Продукционные правила	Граф знаний Граф зависимостей тем: тема А является prerequisite для темы Б	Фреймы Фрейм профиля студента: текущий уровень, пробелы, темп обучения
------------------------------	--	--

Правила назначения дополнительных материалов по результатам тестов		
--	--	--

Вариант 5. Система управления обучением (LMS)				
№	Название датасета	Описание	Формат	Лицензия
1	Open University Learning Analytics (OULAD) https://www.kaggle.com/datasets/rocki37/open-university-learning-analytics-dataset	Поведение 32 593 студентов: кликстримы, оценки, демография.	CSV	CC BY
2	Student Performance (UCI) https://archive.ics.uci.edu/dataset/320/student+performance	Успеваемость португальских школьников: оценки, соцфакторы, посещаемость.	CSV	CC BY
3	Kaggle: Students Performance in Exams https://www.kaggle.com/datasets/spscientist/students-performance-in-exams	1000 студентов, экзаменационные баллы по математике, чтению, письму.	CSV	CC0
4	EdNet — Knowledge Tracing Dataset https://github.com/rriid/ednet	130 млн взаимодействий студентов с образовательной платформой Santa.	CSV	CC BY-NC

Таблица 5. Рекомендуемые источники данных — вариант 5. Система управления обучением (LMS)

Вариант 6. Интернет-торговля (e-commerce)

Задача. Построить систему персонализированных товарных рекомендаций и сегментации покупателей.

Данные. Kaggle: Online Retail Dataset (UCI); Amazon Product Reviews

Парадигмы:

Продукционные правила Правила перекрёстных продаж: если товар X → предложить Y	Семантическая сеть Сеть товаров, категорий и атрибутов	Генетический алгоритм Оптимизация набора рекомендаций под профиль покупателя
---	--	--

Вариант 6. Интернет-торговля (e-commerce)				
№	Название датасета	Описание	Формат	Лицензия
1	Online Retail Dataset (UCI) https://archive.ics.uci.edu/dataset/352/online+retail	541 909 транзакций британского онлайн-магазина подарков за 2010–2011 гг.	Excel/CSV	CC BY
2	Brazilian E-commerce (Olist) https://www.kaggle.com/datasets/olistbr/brazilian-e-commerce	100 000 заказов, товары, отзывы, геолокация продавцов.	CSV	CC BY-NC
3	Amazon Product Reviews https://nijianmo.github.io/amazon/index.html	233 млн отзывов Amazon по 29 категориям товаров (Stanford / UCSD).	JSON/CSV	Research

4	Instacart Market Basket Analysis https://www.kaggle.com/c/instacart-market-basket-analysis/data	3.4 млн заказов, данные о повторных покупках. Отлично для ассоциативных правил.	CSV	CC0
---	--	---	-----	-----

Таблица 6. Рекомендуемые источники данных — вариант 6. Интернет-торговля (e-commerce)

Вариант 7. Агромониторинг и точное земледелие

Задача. Создать систему мониторинга состояния посевов и рекомендаций по агротехническим мероприятиям.

Данные. Kaggle: Crop Recommendation Dataset; FAO open data

Парадигмы:

Продукционные правила Правила выбора культуры и удобрений по типу почвы и климату	Онтология Онтология агрокультур, болезней растений и почвенных характеристик	Генетический алгоритм Оптимизация схемы севооборота для максимизации урожайности
---	--	--

Вариант 7. Агромониторинг и точное земледелие				
№	Название датасета	Описание	Формат	Лицензия
1	Crop Recommendation Dataset https://www.kaggle.com/datasets/atharvaingle/crop-recommendation-dataset	2200 записей: NPK почвы, температура, влажность, pH → рекомендуемая культура.	CSV	CC0
2	Crop and Fertilizer Dataset https://www.kaggle.com/datasets/siddharthss/crop-recommendation-dataset	Рекомендации удобрений по типу почвы, климату и культуре.	CSV	CC0
3	FAO FAOSTAT Agricultural Data https://www.fao.org/faostat/en/	Глобальная статистика ФАО: урожайность, площади, производство по странам.	CSV/Excel	CC BY
4	NDVI / Sentinel-2 (Copernicus) https://dataspace.copernicus.eu/	Спутниковые снимки для мониторинга состояния растительности.	GeoTIFF/API	Open

Таблица 7. Рекомендуемые источники данных — вариант 7. Агромониторинг и точное земледелие

Вариант 8. Энергопотребление и умный дом

Задача. Построить систему анализа и оптимизации энергопотребления в зданиях с выявлением аномалий.

Данные. UCI: Individual Household Electric Power Consumption; Kaggle: Smart Home Dataset

Парадигмы:

Продукционные правила Правила обнаружения аномального потребления и управления нагрузкой	Фреймы Фреймы устройств умного дома: тип, мощность, расписание, состояние	Агентная модель Агенты-устройства, координируемые агентом-контроллером здания
--	---	---

Вариант 8. Энергопотребление и умный дом				
№	Название датасета	Описание	Формат	Лицензия
1	Individual Household Electric Power Consumption (UCI) https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption	2 млн измерений каждую минуту за 4 года. Реальный дом в Сено, Франция.	CSV	CC BY
2	Smart Home Dataset with Weather (Kaggle) https://www.kaggle.com/datasets/taranvee/smart-home-dataset-with-weather-information	Детальное потребление каждого устройства умного дома + погода.	CSV	CC0
3	REDD: Reference Energy Disaggregation Dataset http://redd.csail.mit.edu/	Разбивка потребления по устройствам. MIT. Для задач energy disaggregation.	CSV	Research
4	EnergyPlus Weather Data (DOE) https://energyplus.net/weather	Климатические данные для 2100+ локаций — для моделирования зданий.	EPW/CSV	Public Domain

Таблица 8. Рекомендуемые источники данных — вариант 8. Энергопотребление и умный дом

Вариант 9. Новостная аналитика и медиамониторинг

Задача. Разработать систему автоматической рубрикации новостных статей и обнаружения тематических трендов.

Данные. Kaggle: All the News Dataset; BBC News Dataset; Reuters-21578

Парадигмы:

Продукционные правила Правила классификации статей по ключевым словам и тегам	Семантическая сеть Сеть связей: персона — событие — организация — место	Граф знаний Граф сущностей новостного пространства (NER-граф)
---	---	---

Вариант 9. Новостная аналитика и медиамониторинг				
№	Название датасета	Описание	Формат	Лицензия
1	All the News (Kaggle) https://www.kaggle.com/datasets/snapcrack/all-the-news	200 000+ новостных статей из 15 американских	CSV	CC0

		изданий (2016–2017).		
2	BBC News Classification Dataset https://www.kaggle.com/datasets/hgultekin/bbcnewsarchive	2225 статей BBC по 5 рубрикам: бизнес, политика, спорт, технологии, развлечения.	CSV	CC BY
3	Reuters-21578 (UCI) https://archive.ics.uci.edu/dataset/137/reuters+21578+text+categorization+collection	Классический корпус: 21 578 новостных заметок агентства Reuters.	SGML/CSV	Research
4	CC-News (CommonCrawl) https://commoncrawl.org/blog/news-dataset-available	Миллионы новостных статей из веба, ежемесячные дампы. Доступно через AWS.	WARC/JSON	CC0

Таблица 9. Рекомендуемые источники данных — вариант 9. Новостная аналитика и медиамониторинг

Вариант 10. Промышленное оборудование и предиктивное обслуживание

Задача. Создать систему предсказания отказов оборудования для планирования профилактического обслуживания.

Данные. UCI: AI4I 2020 Predictive Maintenance Dataset; Kaggle: Machine Predictive Maintenance

Парадигмы:

Продукционные правила Правила диагностики неисправностей по телеметрии датчиков	Фреймы Фрейм единицы оборудования: тип, параметры, журнал отказов, регламент	Генетический алгоритм Оптимизация расписания технического обслуживания
---	--	--

Вариант 10. Промышленное оборудование и предиктивное обслуживание

№	Название датасета	Описание	Формат	Лицензия
1	AI4I 2020 Predictive Maintenance Dataset (UCI) https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset	10 000 записей: температура, скорость, нагрузка, тип отказа. Синтетический.	CSV	CC BY

2	Machine Predictive Maintenance (Kaggle) https://www.kaggle.com/datasets/shivamb/machine-predictive-maintenance-classification	10 000 наблюдений с 6 типами отказов оборудования.	CSV	CC0
3	CMAPSS Jet Engine Dataset (NASA) https://www.nasa.gov/intelligent-systems-division/discovery-and-systems-health/pcoe/pcoe-data-set-repository/	Деграция авиадвигателей во времени. Стандарт для задач RUL-прогнозирования.	CSV	Public Domain
4	PHM Society Data Challenge Datasets https://phmsociety.org/data-analysis-competition/	Ежегодные соревновательные датасеты по прогностке технических систем.	CSV	Research

Таблица 10. Рекомендуемые источники данных — вариант 10. Промышленное оборудование и предиктивное обслуживание

Вариант 11. Умный город: безопасность и преступность

Задача. Построить систему анализа криминогенной обстановки и прогнозирования зон повышенного риска.

Данные. Kaggle: Chicago Crime Dataset; Los Angeles Crime Data (data.gov)

Парадигмы:

Продукционные правила Правила выявления паттернов: тип преступления, время, место	Граф знаний Граф: преступление — место — время — тип — подозреваемый	Агентная модель Агенты-патрули, перераспределяющие ресурсы на основе карты риска
---	--	--

Вариант 11. Умный город: безопасность и преступность				
№	Название датасета	Описание	Формат	Лицензия
1	Chicago Crime Dataset (Kaggle) https://www.kaggle.com/datasets/chicago/chicago-crime	7+ млн преступлений с 2001 года: тип, место, арест (да/нет), геокоординаты.	CSV	CC0
2	Los Angeles Crime Data (data.gov) https://catalog.data.gov/dataset/crime-data-from-2020-to-present	Официальные данные LAPD с 2020 года. Обновляется еженедельно.	CSV	Public Domain
3	San Francisco Crime Classification https://www.kaggle.com/c/sf-crime/data	878 049 случаев за 12 лет. Соревновательный датасет Kaggle.	CSV	CC0
4	UK Police Open Data https://data.police.uk/data/	Открытые данные полиции Великобритании: преступления, исходы дел, инциденты.	CSV	Open

Таблица 11. Рекомендуемые источники данных — вариант 11. Умный город: безопасность и преступность

Вариант 12. Туризм и персонализация путешествий

Задача. Разработать систему рекомендаций туристических маршрутов и достопримечательностей с учётом предпочтений путешественника.

Данные. Kaggle: TripAdvisor Hotel Reviews; Yelp Open Dataset

Парадигмы:

Фреймы Фрейм туриста: интересы, бюджет, физические возможности, ранее посещённые места	Семантическая сеть Сеть: достопримечательность — категория — город — страна — сезон	Генетический алгоритм Оптимизация маршрута по критериям: время, стоимость, рейтинг
--	---	--

Вариант 12. Туризм и персонализация путешествий

№	Название датасета	Описание	Формат	Лицензия
1	TripAdvisor Hotel Reviews (Kaggle) https://www.kaggle.com/datasets/andrewmvd/trip-advisor-hotel-reviews	20 491 отзыв с рейтингами 1–5. Для сентимент-анализа и рекомендаций.	CSV	CC0
2	Yelp Open Dataset https://www.yelp.com/dataset	6+ млн отзывов, 200 000 компаний, 11 городов США и Канады.	JSON	Research
3	Expedia Hotel Recommendations https://www.kaggle.com/c/expedia-hotel-recommendations/data	37 млн поисковых событий пользователей Expedia. Для коллаборативной фильтрации.	CSV	CC0
4	OpenStreetMap Overpass API https://overpass-api.de/	Координаты достопримечательностей, кафе, маршрутов — для построения карт.	JSON/XML	ODbL

Таблица 12. Рекомендуемые источники данных — вариант 12. Туризм и персонализация путешествий

Вариант 13. HR-аналитика и управление персоналом

Задача. Создать систему прогнозирования увольнений сотрудников и рекомендаций по удержанию персонала.

Данные. Kaggle: IBM HR Analytics Employee Attrition; UCI: Employee Attrition

Парадигмы:

Продукционные правила Правила риска увольнения: удовлетворённость < порога и стаж < 2 лет → риск высокий	Фреймы Фрейм профиля сотрудника: должность, стаж, зарплата, вовлечённость	Логика (Prolog) Вывод рекомендаций по удержанию на основе профиля сотрудника
---	--	--

Вариант 13. HR-аналитика и управление персоналом

№	Название датасета	Описание	Формат	Лицензия
1	IBM HR Analytics Employee Attrition https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset	1470 сотрудников, 35 признаков. Синтетический датасет IBM для прогноза увольнений.	CSV	CC0

2	HR Analytics Job Change of Data Scientists https://www.kaggle.com/datasets/arashnic/hr-analytics-job-change-of-data-scientists	19 158 специалистов в сфере данных: уйдут или останутся?	CSV	CC0
3	Employee Attrition & Performance (Kaggle) https://www.kaggle.com/datasets/sanjanchaudhari/employees-performance-for-hr-analytics	Производительность сотрудников: обучение, удовлетворённость, оценки.	CSV	CC0
4	Stack Overflow Developer Survey https://insights.stackoverflow.com/survey	Ежегодный опрос 90 000+ разработчиков: зарплаты, технологии, удовлетворённость.	CSV	CC BY-SA

Таблица 13. Рекомендуемые источники данных — вариант 13. HR-аналитика и управление персоналом

Вариант 14. Спортивная аналитика

Задача. Построить систему анализа статистики команд и прогнозирования результатов футбольных матчей.

Данные. Kaggle: European Soccer Database; FIFA World Cup Dataset

Парадигмы:

Продукционные правила Правила оценки формы команды: серия побед, голы, дисквалификации	Семантическая сеть Сеть: игрок — команда — турнир — тренер — позиция	Генетический алгоритм Оптимизация состава команды по игровым показателям
--	--	--

Вариант 14. Спортивная аналитика				
№	Название датасета	Описание	Формат	Лицензия
1	European Soccer Database (Kaggle) https://www.kaggle.com/datasets/hugomathien/soccer	+25 000 матчей, 10 000+ игроков, 11 лиг Европы. Атрибуты игроков из FIFA.	SQLite	CC BY-NC
2	FIFA World Cup Dataset https://www.kaggle.com/datasets/abecklas/fifa-world-cup	Все матчи чемпионатов мира с 1930 по 2014 год.	CSV	CC0
3	StatsBomb Open Data https://github.com/statsbomb/open-data	Детальные событийные данные матчей: пасы, удары, прессинг. Профессиональный уровень.	JSON	CC BY-NC
4	Understat Football xG Data https://www.kaggle.com/datasets/slehkyi/extended-football-stats-for-european-leagues-xg	Ожидаемые голы (xG) для топ-лиг Европы. Для аналитики игровой эффективности.	CSV	CC0

Таблица 14. Рекомендуемые источники данных — вариант 14. Спортивная аналитика

Вариант 15. Телекоммуникации и анализ оттока клиентов

Задача. Разработать систему раннего выявления клиентов, склонных к смене оператора связи (churn prediction).

Данные. UCI: Telecom Churn Dataset; Kaggle: Telco Customer Churn

Парадигмы:

Продукционные правила Правила идентификации групп риска по поведенческим паттернам	Фреймы Фрейм клиента: тариф, звонки, жалобы, история платежей	Логика (Prolog) Логический вывод персональных предложений по удержанию
--	---	--

Вариант 15. Телекоммуникации и анализ оттока клиентов				
№	Название датасета	Описание	Формат	Лицензия
1	Telco Customer Churn (IBM/Kaggle) https://www.kaggle.com/datasets/blaschar/telco-customer-churn	7043 клиента, 20 признаков: тариф, контракт, звонки, отток. Стандартный датасет.	CSV	CC0
2	Telecom Churn Dataset (UCI) https://archive.ics.uci.edu/dataset/563/iranian+churn+dataset	3150 клиентов иранского оператора за 12 месяцев. 14 признаков.	CSV	CC BY
3	Orange Telecom Churn Dataset https://www.kaggle.com/datasets/mnassrib/telecom-churn-datasets	3333 клиента с детализацией звонков, SMS, жалоб на сервис.	CSV	CC0
4	Cell2Cell Churn Dataset https://www.kaggle.com/datasets/jpacse/datasets-for-churn-telecom	71 000 записей — один из крупнейших реальных датасетов по оттоку.	CSV	CC0

Таблица 15. Рекомендуемые источники данных — вариант 15. Телекоммуникации и анализ оттока клиентов

Вариант 16. Цифровые библиотеки и архивы

Задача. Создать интеллектуальную систему каталогизации и тематического поиска в коллекции научных публикаций.

Данные. Kaggle: arXiv Dataset; Semantic Scholar Open Research Corpus

Парадигмы:

Онтология Онтология научных дисциплин и концепций (на основе ACM CCS)	Граф знаний Граф цитирования: статья — автор — журнал — тема — ссылки	Семантическая сеть Сеть связанных понятий для тематического поиска
---	---	--

Вариант 16. Цифровые библиотеки и архивы				
№	Название датасета	Описание	Формат	Лицензия
1	arXiv Dataset (Kaggle) https://www.kaggle.com/datasets/Cornell-University/arxiv	1.7 млн научных статей: заголовок, аннотация, авторы, категория, дата.	JSON	CC0
2	Semantic Scholar Open Research Corpus https://api.semanticscholar.org/corpus/	200+ млн публикаций с метаданными и графом цитирования.	JSON	Open
3	CrossRef REST API https://api.crossref.org/	Метаданные 140+ млн публикаций. DOI, авторы, журналы, цитирования.	JSON/API	CC0
4	CORE Open Access Dataset https://core.ac.uk/data	200+ млн открытых научных статей в полнотекстовом формате.	JSON	CC BY

Таблица 16. Рекомендуемые источники данных — вариант 16. Цифровые библиотеки и архивы

Вариант 17. Страхование и оценка рисков

Задача. Построить экспертную систему оценки страховых рисков и выявления мошеннических заявлений.

Данные. Kaggle: Insurance Fraud Detection; UCI: Auto Insurance in Sweden

Параdigмы:

Продукционные правила Правила флажирования подозрительных заявлений по аномальным признакам	Фреймы Фрейм страхового случая: тип, ущерб, история, клиент, обстоятельства	Логика (Prolog) Логический вывод вероятности мошенничества и обоснование решения
---	---	--

Вариант 17. Страхование и оценка рисков				
№	Название датасета	Описание	Формат	Лицензия
1	Insurance Fraud Detection (Kaggle) https://www.kaggle.com/datasets/bunttyshah/auto-insurance-claims-data	15 420 страховых требований с флагом мошенничества. Авто-страхование.	CSV	CC0
2	Auto Insurance in Sweden (UCI) https://archive.ics.uci.edu/dataset/108/auto+insurance	63 наблюдения: кол-во требований и суммарные выплаты. Простой, для регрессии.	CSV	CC BY
3	Porto Seguro Safe Driver Prediction https://www.kaggle.com/c/porto-seguro-safe-driver-prediction/data	595 212 клиентов Porto Seguro. Предсказание вероятности страхового случая.	CSV	CC0
4	Medical Insurance Cost Dataset https://www.kaggle.com/datasets/mirichoi0218/insurance	1338 записей с медицинскими страховыми расходами. Для регрессии стоимости.	CSV	CC0

Таблица 17. Рекомендуемые источники данных — вариант 17. Страхование и оценка рисков

Вариант 18. Водоснабжение и качество воды

Задача. Разработать систему мониторинга качества питьевой воды и прогнозирования нарушений санитарных норм.

Данные. Kaggle: Water Quality Dataset; WHO / EPA открытые данные

Параdigмы:

Продукционные правила Правила классификации проб воды по химическим показателям	Онтология Онтология загрязнителей воды, источников и санитарных стандартов	Агентная модель Агенты-датчики на объектах водозабора, передающие данные в центр
---	--	--

Вариант 18. Водоснабжение и качество воды				
№	Название датасета	Описание	Формат	Лицензия
1	Water Quality Dataset (Kaggle)	7999 образцов воды: 20 химических параметров +	CSV	CC0

	https://www.kaggle.com/datasets/mssmartypants/water-quality	бинарная пригодность к питью.		
2	Water Potability Dataset https://www.kaggle.com/datasets/adityakadiwal/water-potability	3276 образцов: pH, жёсткость, мутность, хлор. Классификация пригодности.	CSV	CC0
3	EPA ECHO Water Quality Data https://echo.epa.gov/tools/data-downloads	Данные агентства EPA по нарушениям норм качества воды в США.	CSV	Public Domain
4	WHO/UNICEF JMP Water Data https://washdata.org/data/downloads	Глобальный мониторинг доступа к питьевой воде. 200 стран, 2000–2022 гг.	CSV/Excel	Open

Таблица 18. Рекомендуемые источники данных — вариант 18. Водоснабжение и качество воды

Вариант 19. Недвижимость и оценка объектов

Задача. Создать систему оценки рыночной стоимости жилой недвижимости и анализа инвестиционной привлекательности.

Данные. Kaggle: House Prices (Ames, Iowa); Boston Housing Dataset (UCI)

Парадигмы:

Продукционные правила Правила коррекции базовой цены по местоположению, состоянию, инфраструктуре	Фреймы Фрейм объекта недвижимости: площадь, тип, год, район, инфраструктура	Генетический алгоритм Поиск оптимального инвестиционного портфеля объектов
---	---	--

Вариант 19. Недвижимость и оценка объектов				
№	Название датасета	Описание	Формат	Лицензия
1	House Prices: Advanced Regression Techniques https://www.kaggle.com/c/house-prices-advanced-regression-techniques/data	1460 домов Эймса (Айова): 79 признаков. Соревновательный датасет Kaggle.	CSV	CC0
2	Boston Housing Dataset (UCI) https://archive.ics.uci.edu/dataset/162/housing	506 районов Бостона. Классический датасет регрессии цен.	CSV	CC BY
3	Melbourne Housing Market (Kaggle) https://www.kaggle.com/datasets/dansbecker/melbourne-housing-snapshot	34 857 объектов Мельбурна: тип, площадь, район, цена продажи.	CSV	CC0
4	NYC Property Sales Data https://www.kaggle.com/datasets/new-york-city/nyc-property-sales	Реальные сделки недвижимости Нью-Йорка. Открытые данные городского реестра.	CSV	Public Domain

Таблица 19. Рекомендуемые источники данных — вариант 19. Недвижимость и оценка объектов

Вариант 20. Фармацевтика и лекарственные взаимодействия

Задача. Построить систему проверки совместимости лекарственных препаратов и поддержки назначений для врачей.

Данные. DrugBank Open Data; Kaggle: Drug Interaction Dataset; RxNorm

Парадигмы:

Онтология Онтология препаратов, химических групп, показаний и противопоказаний	Производственные правила Правила: несовместимость классов препаратов при одновременном приёме	Граф знаний Граф взаимодействий: препарат — механизм — побочный эффект — заболевание
--	---	--

Вариант 20. Фармацевтика и лекарственные взаимодействия

№	Название датасета	Описание	Формат	Лицензия
1	DrugBank Open Structures https://go.drugbank.com/releases/latest	14 000+ препаратов: структура, мишени, взаимодействия, показания.	XML/CSV	CC BY-NC
2	Drug–Drug Interaction Dataset (DDI) https://www.kaggle.com/datasets/martj42/drug-drug-interaction-dataset	192 000 пар препаратов с типом взаимодействия. Стандарт NLP-задачи.	CSV	CC0
3	FDA FAERS (Adverse Events Reporting) https://fis.fda.gov/extensions/FPD-QDE-FAERS/FPD-QDE-FAERS.html	Реальные отчёты о нежелательных реакциях на препараты (США, FDA).	CSV	Public Domain
4	SIDER Side Effect Resource http://sideeffects.embl.de/	1430 препаратов × 5868 побочных эффектов. Связь препарат — симптом.	CSV	CC BY-NC

Таблица 20. Рекомендуемые источники данных — вариант 20. Фармацевтика и лекарственные взаимодействия

Вариант 21. Логистика и управление цепочками поставок

Задача. Разработать систему оптимизации маршрутов доставки и управления складскими запасами.

Данные. Kaggle: Supply Chain Dataset; Brazilian E-commerce (Olist)

Парадигмы:

Производственные правила Правила пополнения запасов: если уровень < минимума → заказ	Агентная модель Агенты-склады и агенты-транспортные средства с координацией	Генетический алгоритм Оптимизация маршрутов доставки (задача VRP)
--	---	---

Вариант 21. Логистика и управление цепочками поставок

№	Название датасета	Описание	Формат	Лицензия
1	Supply Chain Dataset (DataCo) https://www.kaggle.com/datasets/shashwatwork/dataco-smart-supply-chain-for-big-data-analysis	180 519 транзакций: заказы, клиенты, склады, задержки доставки.	CSV	CC0
2	Brazilian E-Commerce Supply Chain (Olist) https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce	100 000 заказов с продавцами, доставкой, геолокацией.	CSV	CC BY-NC

3	UCI Online Retail II https://archive.ics.uci.edu/dataset/502/online+retail+ii	1 млн транзакций 2009–2011 гг. для анализа логистики и ассортимента.	Excel/CSV	CC BY
4	VRPTW Benchmark (Solomon instances) http://web.cba.neu.edu/~msolomon/problems.htm	Стандартные тестовые экземпляры задачи маршрутизации транспорта с окнами времени.	TXT	Free

Таблица 21. Рекомендуемые источники данных — вариант 21. Логистика и управление цепочками поставок

Вариант 22. Кибербезопасность и обнаружение вторжений

Задача. Создать систему обнаружения аномалий в сетевом трафике и классификации типов кибератак.

Данные. UCI/Kaggle: NSL-KDD, CICIDS-2017 Network Intrusion Detection

Парадигмы:

Продукционные правила Правила сигнатурного обнаружения: паттерны известных атак	Граф знаний Граф: IP-адрес — тип трафика — событие — атака — уязвимость	Агентная модель Агенты-мониторы на узлах сети, сигнализирующие центральному агенту
---	---	--

Вариант 22. Кибербезопасность и обнаружение вторжений

№	Название датасета	Описание	Формат	Лицензия
1	NSL-KDD Intrusion Detection Dataset https://www.kaggle.com/datasets/hassan06/nsikdd	Улучшенная версия KDD'99. 125 973 обучающих записей, 22 типа атак.	CSV	CC0
2	CICIDS-2017 (Canadian Institute) https://www.unb.ca/cic/datasets/ids-2017.html	Реалистичный датасет с 15 типами атак: DoS, BruteForce, XSS, SQLi и др.	CSV	Research
3	UNSW-NB15 Dataset https://research.unsw.edu.au/projects/unswnb15-dataset	2 млн записей сетевого трафика, 9 типов атак + нормальный трафик.	CSV	Research
4	CTU-13 Botnet Traffic Dataset https://www.stratosphereips.org/datasets-ctu13	13 сценариев ботнет-атак с реальным трафиком. Прага, CTU University.	PCAP/CSV	Research

Таблица 22. Рекомендуемые источники данных — вариант 22. Кибербезопасность и обнаружение вторжений

Вариант 23. Образование: анализ успеваемости школьников

Задача. Построить систему раннего выявления учеников, нуждающихся в дополнительной поддержке, и рекомендаций для педагогов.

Данные. UCI: Student Performance Dataset; Kaggle: Students Performance in Exams

Парадигмы:

Продукционные правила	Фреймы	Логика (Prolog)
------------------------------	---------------	------------------------

Правила определения зоны риска: пропуски + оценки ниже порога	Фрейм ученика: успеваемость по предметам, посещаемость, социальный профиль	Логический вывод персональных рекомендаций для классного руководителя
---	--	---

Вариант 23. Образование: анализ успеваемости школьников				
№	Название датасета	Описание	Формат	Лицензия
1	Student Performance (UCI) https://archive.ics.uci.edu/dataset/320/student+performance	649 учеников двух португальских школ: оценки G1/G2/G3, соцфакторы.	CSV	CC BY
2	Students Performance in Exams (Kaggle) https://www.kaggle.com/datasets/spscientist/students-performance-in-exams	1000 учеников. Баллы по математике, чтению, письму + демография.	CSV	CC0
3	PISA 2022 Dataset (OECD) https://www.oecd.org/pisa/data/2022database/	690 000+ учеников из 81 страны. Грамотность, математика, естествознание.	SAS/CSV	Open
4	Learning Measurement Dataset (Kaggle) https://www.kaggle.com/datasets/aljarah/xAPI-Edu-Data	480 студентов, 16 признаков поведения в LMS → 3 уровня успеваемости.	CSV	CC0

Таблица 23. Рекомендуемые источники данных — вариант 23. Образование: анализ успеваемости школьников

Вариант 24. Переработка отходов и экология города

Задача. Разработать систему классификации и маршрутизации твёрдых бытовых отходов для оптимизации переработки.

Данные. Kaggle: Waste Classification Data; EPA открытые данные по отходам

Парадигмы:

Продукционные правила Правила классификации отходов по материалу и условиям переработки	Онтология Онтология типов отходов, материалов, методов утилизации и нормативов	Агентная модель Агенты-мусоровозы, оптимизирующие маршрут объезда
---	--	---

Вариант 24. Переработка отходов и экология города				
№	Название датасета	Описание	Формат	Лицензия
1	Waste Classification Data (Kaggle) https://www.kaggle.com/datasets/techsash/waste-classification-data	25 077 изображений отходов: органика, переработка (2 класса). Для CV.	Images/CSV	CC0
2	Garbage Classification (12 classes) https://www.kaggle.com/datasets/mostafaabla/garbage-classification	15 515 фото в 12 категориях: пластик, стекло, металл, бумага и др.	Images	CC0
3	EPA MSW Data (Municipal Solid Waste) https://www.epa.gov/facts-and-figures-about-materials-waste-and-recycling	Статистика твёрдых бытовых отходов США по материалам, 1960–2018.	Excel/CSV	Public Domain

4	Global Waste Management Outlook (UN) https://www.unep.org/resources/report/global-waste-management-outlook-2024	Данные ООН по обращению с отходами в 167 странах.	Excel	Open
---	--	---	-------	------

Таблица 24. Рекомендуемые источники данных — вариант 24. Переработка отходов и экология города

Вариант 25. Ресторанный бизнес и гастрономия

Задача. Создать систему анализа отзывов посетителей и рекомендаций по улучшению меню и сервиса ресторанов.

Данные. Yelp Open Dataset (отзывы); Kaggle: Zomato Restaurants Data

Парадигмы:

Производственные правила Правила формирования сводной оценки ресторана по критериям	Семантическая сеть Сеть: блюдо — ингредиент — кухня — аллерген — диета	Граф знаний Граф: отзыв — клиент — блюдо — ресторан — оценка — тема
---	--	---

Вариант 25. Ресторанный бизнес и гастрономия				
№	Название датасета	Описание	Формат	Лицензия
1	Yelp Open Dataset https://www.yelp.com/dataset	6.9 млн отзывов, 150 000 компаний, фото, чекины. Официальный датасет.	JSON	Research
2	Zomato Restaurants Data (Kaggle) https://www.kaggle.com/datasets/shrutimehta/zomato-restaurants-data	9551 ресторан из 15 стран: кухня, рейтинг, стоимость, онлайн-доставка.	CSV	CC0
3	TripAdvisor Restaurant Reviews https://www.kaggle.com/datasets/stefanoleone992/tripadvisor-european-restaurants	1.1 млн европейских ресторанов с рейтингами и тегами кухни.	CSV	CC0
4	Open Food Facts https://world.openfoodfacts.org/data	2.6 млн продуктов питания: состав, пищевая ценность, аллергены.	CSV/JSON	ODbL

Таблица 25. Рекомендуемые источники данных — вариант 25. Ресторанный бизнес и гастрономия

Вариант 26. Авиация и безопасность полётов

Задача. Построить экспертную систему анализа инцидентов и оценки рисков при выполнении авиарейсов.

Данные. NTSB Aviation Accident Database; Kaggle: Airline Safety; FAA open data

Парадигмы:

Производственные правила Правила классификации инцидентов по типу, фазе полёта, причине	Онтология Онтология авиационных рисков: отказ — причина — фаза полёта — последствие	Логика (Prolog) Логический вывод цепочки причинно-следственных связей инцидента
---	---	---

Вариант 26. Авиация и безопасность полётов

№	Название датасета	Описание	Формат	Лицензия
1	NTSB Aviation Accident Database https://www.nts.gov/Pages/AviationQueryV2.aspx	80 000+ авиационных происшествий США с 1982 года. Официальный реестр NTSB.	CSV	Public Domain
2	Airline Safety Dataset (Kaggle) https://www.kaggle.com/datasets/fivethirtyeight/fivethirtyeight-airline-safety	Статистика безопасности 56 авиакомпаний: инциденты, фатальные исходы.	CSV	CC0
3	FAA Aviation Data (Wildlife Strikes) https://wildlife.faa.gov/downloads.aspx	Столкновения с птицами. 220 000 инцидентов с 1990 по 2022 год.	CSV	Public Domain
4	OpenSky Network ADS-B Data https://opensky-network.org/data/raw-data	Открытые данные о воздушном движении в реальном времени и исторические.	CSV/Parquet	CC BY

Таблица 26. Рекомендуемые источники данных — вариант 26. Авиация и безопасность полётов

Вариант 27. Банковское дело и анализ транзакций

Задача. Разработать систему обнаружения мошеннических транзакций в реальном времени.

Данные. Kaggle: Credit Card Fraud Detection; IEEE-CIS Fraud Detection

Парадигмы:

Продукционные правила Правила флажирования: нетипичная страна + крупная сумма → проверка	Фреймы Фрейм профиля клиента: типичные операции, лимиты, история, устройства	Агентная модель Агент-монитор транзакций, взаимодействующий с агентом верификации
--	--	---

Вариант 27. Банковское дело и анализ транзакций				
№	Название датасета	Описание	Формат	Лицензия
1	Credit Card Fraud Detection (Kaggle) https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud	284 807 транзакций, 492 мошеннических. Анонимизированные PCA-признаки.	CSV	CC0
2	IEEE-CIS Fraud Detection https://www.kaggle.com/c/ieee-fraud-detection/data	590 540 транзакций. Детальные признаки: устройство, email, адрес, время.	CSV	CC0
3	PaySim Mobile Money Transactions https://www.kaggle.com/datasets/ealaxi/paysim1	6.3 млн синтетических транзакций мобильных платежей с флагом мошенничества.	CSV	CC0
4	Bank Marketing Dataset (UCI) https://archive.ics.uci.edu/dataset/222/bank+marketing	45 211 контактов португальского банка: телемаркетинг + подписка на депозит.	CSV	CC BY

Таблица 27. Рекомендуемые источники данных — вариант 27. Банковское дело и анализ транзакций

Вариант 28. Климат и метеорология

Задача. Создать систему анализа климатических данных и прогнозирования экстремальных погодных событий.

Данные. NOAA Global Surface Temperature; Kaggle: Weather Prediction Dataset

Парадигмы:

Производственные правила Правила классификации погодных условий и оповещений населения	Онтология Онтология метеорологических явлений, параметров и географических зон	Генетический алгоритм Оптимизация параметров метеорологической модели прогноза
--	--	--

Вариант 28. Климат и метеорология				
№	Название датасета	Описание	Формат	Лицензия
1	NOAA Global Surface Temperature (NOAAGlobalTemp) https://www.ncei.noaa.gov/products/land-based-station/noaa-global-surface-temperature	Глобальная температура поверхности с 1850 года. Официальные данные NOAA.	CSV/NetCDF	Public Domain
2	Weather Prediction Dataset (Kaggle) https://www.kaggle.com/datasets/ananthr1/weather-prediction	Погодные данные по 18 европейским городам: ежедневные наблюдения с 2000 г.	CSV	CC0
3	Historical Hourly Weather Data (Kaggle) https://www.kaggle.com/datasets/selfishgene/historical-hourly-weather-data	Почасовые данные 30 городов США за 5 лет: температура, влажность, давление.	CSV	CC0
4	ERA5 Reanalysis (Copernicus / ECMWF) https://cds.climate.copernicus.eu/cdsapp	Глобальный климатический реанализ с 1940 года. Разрешение 0.25°, почасовое.	NetCDF/GRIB	Open

Таблица 28. Рекомендуемые источники данных — вариант 28. Климат и метеорология

Вариант 29. Игровая индустрия и геймдизайн

Задача. Построить систему анализа поведения игроков и динамической адаптации сложности игрового процесса.

Данные. Kaggle: League of Legends Ranked Games; Steam Game Reviews

Парадигмы:

Производственные правила Правила адаптации: если winrate < 30% за последние 5 игр → снизить сложность	Фреймы Фрейм игрока: стиль игры, сильные стороны, предпочтения, уровень	Агентная модель Агенты-боты с адаптивным поведением, реагирующие на тактику игрока
---	---	--

Вариант 29. Игровая индустрия и геймдизайн				
№	Название датасета	Описание	Формат	Лицензия

1	League of Legends Ranked Games (Kaggle) https://www.kaggle.com/datasets/bobbyscience/league-of-legends-diamond-ranked-games-10-min	9879 матчей Diamond-ранга. Статистика первых 10 минут + победитель.	CSV	CC0
2	Steam Games Dataset (Kaggle) https://www.kaggle.com/datasets/nikdavis/steam-store-games	27 000 игр Steam: жанр, рейтинг, дата выхода, цена, кол-во отзывов.	CSV	CC0
3	Video Game Sales Dataset https://www.kaggle.com/datasets/regorut/videogamesales	16 500+ игр с продажами по регионам. Для анализа рыночных трендов.	CSV	CC0
4	Dota 2 Matches Dataset https://www.kaggle.com/datasets/devinanzelmo/dota-2-matches	50 000 матчей с детальной статистикой игроков. Для агентного моделирования.	CSV	CC0

Таблица 29. Рекомендуемые источники данных — вариант 29. Игровая индустрия и геймдизайн

Вариант 30. Социальные сети и анализ сообществ

Задача. Разработать систему выявления тематических сообществ и ключевых узлов влияния в социальных сетях.

Данные. Stanford SNAP: Social Network Datasets; Kaggle: Twitter Sentiment

Парадигмы:

Граф знаний Граф социальной сети: пользователь — подписка — тема — публикация	Семантическая сеть Семантическая сеть интересов и тематических связей пользователей	Генетический алгоритм Оптимизация разбиения графа на сообщества (задача graph clustering)
---	---	---

Вариант 30. Социальные сети и анализ сообществ				
№	Название датасета	Описание	Формат	Лицензия
1	SNAP: Stanford Social Network Datasets https://snap.stanford.edu/data/	Графы Twitter, Facebook, Reddit, Epinions. Стандарт для анализа сетей.	TXT/CSV	Free
2	Twitter Sentiment Analysis (Kaggle) https://www.kaggle.com/datasets/kazanova/sentiment140	1.6 млн твитов с разметкой позитив/негатив. Для NLP и графов настроений.	CSV	CC0
3	Reddit Comments Dataset (Pushshift) https://academicorrents.com/details/c398a571976c78d346c325bd75c47b82ccf03be2	Миллиарды постов и комментариев Reddit. Срез данных доступен по запросу.	JSON	CC0

4	Facebook Large Page–Page Network (SNAP) https://snap.stanford.edu/data/facebook-large-page-page-network.html	22 470 страниц Facebook, 171 002 взаимных подписок. Для кластеризации.	CSV	Free
---	---	--	-----	------

Таблица 30. Рекомендуемые источники данных — вариант 30. Социальные сети и анализ сообществ

Вариант 31. Умное сельское хозяйство и теплицы

Задача. Разработать систему управления микроклиматом теплицы с автоматическим регулированием температуры, влажности и освещённости на основе фаз роста растений.

Данные. Greenhouse Gas Sensors Dataset (UCI); Plant Growth Monitoring (Kaggle); Smart Farming IoT Dataset; Crop Recommendation Dataset

Парадигмы:

Производственные правила Правила управления: ЕСЛИ температура > порога И фаза=цветение → снизить температуру	Фреймы Фрейм культуры: слоты — вид растения, фаза роста, оптимальные параметры среды	Агентная модель Агенты-датчики и агент-контроллер; взаимодействие через события
--	--	---

Вариант 31. Умное сельское хозяйство и теплицы				
№	Название датасета	Описание	Формат	Лицензия
1	Greenhouse Gas Sensors Dataset (UCI) https://archive.ics.uci.edu/dataset/322/gas+sensor+array+under+dynamic+gas+mixture	Данные газовых датчиков в условиях изменяемой среды.	CSV	CC BY
2	Plant Growth Monitoring (Kaggle) https://www.kaggle.com/datasets/jmesplana/plant-growth-data-simulation	Параметры роста растений в зависимости от условий среды.	CSV	CC0
3	Smart Farming IoT Dataset https://www.kaggle.com/datasets/eliasmeire/iot-smart-farming-dataset	IoT-данные умной фермы: температура, влажность, pH почвы.	CSV	CC0
4	Crop Recommendation Dataset https://www.kaggle.com/datasets/atharvaingle/crop-recommendation-dataset	Рекомендации культур по климатическим и почвенным параметрам.	CSV	CC0

Таблица 31. Рекомендуемые источники данных — вариант 31. Умное сельское хозяйство и теплицы

Вариант 32. Юридическая экспертиза и анализ договоров

Задача. Построить экспертную систему для автоматического анализа типовых гражданско-правовых договоров: выявление рискованных условий, несоответствий и рекомендации по корректировке.

Данные. CUAD: Contract Understanding Atticus Dataset; LEDGAR (Contract Provisions); Contract NLI Dataset; ECtHR Cases Dataset

Парадигмы:

Продукционные правила Правила выявления рисков: ЕСЛИ штраф > 50% суммы договора → «кабальное условие»	Онтология Онтология правовых понятий: договор, сторона, обязательство, санкция, форс-мажор	Логика (Prolog) Логический вывод о законности условий и наличии противоречий между пунктами
---	--	---

Вариант 32. Юридическая экспертиза и анализ договоров

№	Название датасета	Описание	Формат	Лицензия
1	CUAD: Contract Understanding Atticus Dataset https://www.atticusproject.ai/cuad	510 юридических договоров с разметкой 41 категории условий.	JSON/PDF	CC BY 4.0
2	LEDGAR (Contract Provisions) https://drive.switch.ch/index.php/s/j9S0GRMAbGZKa1A	60 000 положений из договоров SEC с тематической разметкой.	JSON	CC BY
3	Contract NLI Dataset https://stanfordnlp.github.io/contract-nli/	607 договоров NDA с разметкой логических отношений.	JSON	CC BY 4.0
4	ECtHR Cases Dataset https://archive.org/details/ECtHR-Dataset	Решения Европейского суда по правам человека.	JSON	Public Domain

Таблица 32. Рекомендуемые источники данных — вариант 32. Юридическая экспертиза и анализ договоров

Вариант 33. Оценка качества программного обеспечения

Задача. Создать систему автоматической оценки качества программного кода: выявление дефектов, антипаттернов, прогнозирование числа ошибок в модулях.

Данные. NASA Software Defect Datasets (PROMISE); Software Defect Prediction — AR1 (PROMISE/OpenML); Bug Prediction Dataset; GitHub Issue Tracker Data

Парадигмы:

Продукционные правила Правила обнаружения антипаттернов: ЕСЛИ цикломатическая сложность > 15 → предупреждение	Граф знаний Граф зависимостей модулей: модуль → функция → метрика → дефект	Фреймы Фреймы программных компонентов: слоты — метрики, история изменений, дефектность
---	--	--

Вариант 33. Оценка качества программного обеспечения

№	Название датасета	Описание	Формат	Лицензия
---	-------------------	----------	--------	----------

1	NASA Software Defect Datasets (PROMISE) https://github.com/klainfo/NASADefectDataset	Метрики кода и дефекты модулей NASA (CM1, JM1, KC1, PC1).	CSV	CC0
2	Software Defect Prediction — AR1 (PROMISE/OpenML) https://www.openml.org/d/1059	Метрики Холстеда и МакКейба проекта AR1 (турецкий Softlab, embedded ПО).	CSV	CC BY
3	Bug Prediction Dataset https://bug.inf.usi.ch/	Метрики кода и история дефектов 5 Java-проектов.	CSV	Free
4	GitHub Issue Tracker Data https://archive.org/details/ghtorrent-20160301	История задач, коммитов и исправлений популярных репозиторий.	JSON/CSV	CC0

Таблица 33. Рекомендуемые источники данных — вариант 33. Оценка качества программного обеспечения

Вариант 34. Рекомендательная система для кино и стриминга

Задача. Разработать гибридную рекомендательную систему для стримингового сервиса с учётом контентных характеристик фильмов, предпочтений пользователей и контекста просмотра.

Данные. MovieLens 25M Dataset; IMDb Dataset (Non-commercial); Netflix Prize Data; The Movies Dataset (Kaggle)

Парадигмы:

Семантическая сеть Сеть концептов: жанр → поджанр → фильм → актёр → режиссёр	Граф знаний Граф взаимодействий: пользователь — просмотр — фильм — оценка — похожий_фильм	Продукционные правила Правила контекстной фильтрации: ЕСЛИ время=вечер И настроение=комедия → рекомендовать лёгкие жанры
---	---	---

Вариант 34. Рекомендательная система для кино и стриминга				
№	Название датасета	Описание	Формат	Лицензия
1	MovieLens 25M Dataset https://grouplens.org/datasets/movielens/25m/	25 млн оценок 62 000 фильмов от 162 000 пользователей.	CSV	CC BY 4.0
2	IMDb Dataset (Non-commercial) https://developer.imdb.com/non-commercial-datasets/	Официальные данные IMDb: рейтинги, жанры, актёры, режиссёры.	TSV	Non-commercial
3	Netflix Prize Data https://www.kaggle.com/datasets/netflix-inc/netflix-prize-data	100 млн оценок от 480 000 пользователей — классический датасет.	TXT/CSV	CC0
4	The Movies Dataset (Kaggle) https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset	45 000 фильмов: бюджет, выручка, ключевые слова, состав команды.	CSV	CC0

Таблица 34. Рекомендуемые источники данных — вариант 34. Рекомендательная система для кино и стриминга

Вариант 35. Анализ дорожно-транспортных происшествий

Задача. Построить систему анализа причин дорожно-транспортных происшествий и прогнозирования опасных участков дороги для приоритизации мер безопасности.

Данные. UK Road Safety: Traffic Accidents (Kaggle); US Accidents (Kaggle); Accidents in France (data.gouv.fr); Road Traffic Severity (Kaggle)

Парадигмы:

Производственные правила Правила классификации тяжести ДТП по условиям: дорога, погода, скорость, время суток	Онтология Онтология факторов ДТП: участник, транспортное средство, инфраструктура, внешние условия	Генетический алгоритм Оптимизация расстановки предупреждающих знаков и дорожных камер
---	--	---

Вариант 35. Анализ дорожно-транспортных происшествий

№	Название датасета	Описание	Формат	Лицензия
1	UK Road Safety: Traffic Accidents (Kaggle) https://www.kaggle.com/datasets/tsjaras/uk-road-safety-accidents-and-vehicles	1.8 млн ДТП Великобритании 2000–2016 гг. с детальными атрибутами.	CSV	Open Government
2	US Accidents (Kaggle) https://www.kaggle.com/datasets/sobhanmoosavi/us-accidents	7.7 млн аварий на дорогах США 2016–2023 гг.	CSV	CC BY-NC-SA
3	Accidents in France (data.gouv.fr) https://www.data.gouv.fr/en/datasets/bases-de-donnees-annuelles-des-accidents-corporels-de-la-circulation-routiere-annees-de-2005-a-2022/	Ежегодные сводки ДТП Франции с 2005 года.	CSV	Open License
4	Road Traffic Severity (Kaggle) https://www.kaggle.com/datasets/saurabhshahane/road-traffic-accidents	12 000 ДТП Аддис-Абебы с классификацией тяжести.	CSV	CC0

Таблица 35. Рекомендуемые источники данных — вариант 35. Анализ дорожно-транспортных происшествий

Вариант 36. Управление складом и инвентаризация

Задача. Создать интеллектуальную систему управления складскими запасами: прогнозирование потребности, оптимизация закупок и автоматическая расстановка товаров.

Данные. Retail Inventory & Sales (Kaggle); Online Retail Dataset (UCI); Supply Chain Dataset (Kaggle); Demand Forecasting Dataset

Парадигмы:

Производственные правила Правила пополнения запасов: ЕСЛИ остаток < минимального уровня И срок поставки > 3 дней → срочный заказ	Фреймы Фреймы SKU: слоты — артикул, категория, оборачиваемость, минимальный/максимальный запас	Генетический алгоритм Оптимизация размещения товаров в ячейках по критериям оборачиваемости и совместимости
--	--	---

Вариант 36. Управление складом и инвентаризация

№	Название датасета	Описание	Формат	Лицензия
---	-------------------	----------	--------	----------

1	Retail Inventory & Sales (Kaggle) https://www.kaggle.com/datasets/berkayalan/retail-sales-data	История продаж розничной сети с уровнями запасов.	CSV	CC0
2	Online Retail Dataset (UCI) https://archive.ics.uci.edu/dataset/352/online+retail	541 909 транзакций британского онлайн-ритейлера за 2010–2011 гг.	XLSX	CC BY
3	Supply Chain Dataset (Kaggle) https://www.kaggle.com/datasets/harshsingh2209/supply-chain-analysis	Данные цепочки поставок косметических товаров.	CSV	CC0
4	Demand Forecasting Dataset https://www.kaggle.com/datasets/felixzhao/productdemandforecasting	2 млн записей спроса по 2 000 продуктов из 4 складов.	CSV	CC0

Таблица 36. Рекомендуемые источники данных — вариант 36. Управление складом и инвентаризация

Вариант 37. Диагностика и обслуживание автомобилей

Задача. Разработать экспертную систему диагностики неисправностей автомобилей по OBD-кодам, симптомам и параметрам двигателя с рекомендациями по техническому обслуживанию.

Данные. Vehicle OBD-II DTC Database; Car Defects and Complaints (NHTSA); Vehicle Sensor Anomaly Dataset; Auto MPG Dataset (UCI)

Парадигмы:

Продукционные правила Диагностические деревья: ЕСЛИ P0301 И вибрация → пропуск воспламенения в 1-м цилиндре	Онтология Онтология автомобиля: система → узел → компонент → неисправность → причина → устранение	Фреймы Фреймы кодов ошибок: слоты — код, описание, вероятные причины, срочность, стоимость ремонта
---	---	--

Вариант 37. Диагностика и обслуживание автомобилей				
№	Название датасета	Описание	Формат	Лицензия
1	Vehicle OBD-II DTC Database https://www.kaggle.com/datasets/tomasmantero/vehicle-dtc-obdii-diagnostic-codes	Словарь 1 500+ кодов OBD-II с описаниями и системами.	CSV	CC0
2	Car Defects and Complaints (NHTSA) https://www.nhtsa.gov/vehicle-safety/complaints	Жалобы владельцев на дефекты по маркам и моделям.	CSV	Public Domain
3	Vehicle Sensor Anomaly Dataset https://www.kaggle.com/datasets/cynthiacheng/automobile-dataset	Параметры двигателя, расход топлива и технические характеристики.	CSV	CC0
4	Auto MPG Dataset (UCI) https://archive.ics.uci.edu/dataset/9/auto+mpg	Технические характеристики 398 автомобилей 1970-х–80-х.	CSV	CC BY

Таблица 37. Рекомендуемые источники данных — вариант 37. Диагностика и обслуживание автомобилей

Вариант 38. Управление проектами и оценка рисков

Задача. Построить систему интеллектуальной поддержки управления IT-проектами: оценка рисков срыва сроков, распределение ресурсов и идентификация «узких мест».

Данные. SEERA Software Projects Dataset; Jira Issue Tracking (Open Source); GitHub Project Data (GHTorrent); Software Effort Estimation Dataset

Парадигмы:

Производственные правила Правила эскалации рисков: ЕСЛИ burndown отклоняется > 20% И осталось < 2 спринтов → красный статус	Фреймы Фрейм задачи: слоты — оценка, исполнитель, приоритет, зависимости, статус, фактические трудозатраты	Логика (Prolog) Логический вывод о совместимости ресурсов, критическом пути и блокирующих зависимостях
---	--	--

Вариант 38. Управление проектами и оценка рисков				
№	Название датасета	Описание	Формат	Лицензия
1	SEERA Software Projects Dataset https://zenodo.org/record/3629226	1 174 завершённых IT-проекта с оценками и фактическими данными.	XLSX	CC BY 4.0
2	Jira Issue Tracking (Open Source) https://zenodo.org/record/3576769	История задач крупных open-source проектов из Jira.	JSON/CSV	CC BY
3	GitHub Project Data (GHTorrent) https://ghntorrent.org/	Открытые данные GitHub: коммиты, pull requests, issues.	JSON/CSV	CC0
4	Software Effort Estimation Dataset https://www.kaggle.com/datasets/reenal/software-project-effort-estimation	Данные по оценке трудозатрат в программных проектах.	CSV	CC0

Таблица 38. Рекомендуемые источники данных — вариант 38. Управление проектами и оценка рисков

Вариант 39. Умный дом и интернет вещей

Задача. Создать систему управления умным домом с автоматизацией сценариев, обнаружением аномалий в поведении жильцов и адаптацией к предпочтениям.

Данные. CASAS Smart Home Dataset; UCI Activity Recognition (OPPORTUNITY); Smart Home Energy Dataset (UK-DALE); IoT Device Logs (Kaggle)

Парадигмы:

Производственные правила Сценарии: ЕСЛИ время=23:00 И движения нет 30 мин → режим «ночь»; ЕСЛИ утечка газа → тревога	Агентная модель Агенты-устройства (лампа, термостат, замок) и агент-координатор сценариев	Фреймы Фрейм устройства: слоты — тип, местоположение, состояние, расписание, энергопотребление
--	---	--

Вариант 39. Умный дом и интернет вещей				
№	Название датасета	Описание	Формат	Лицензия

1	CASAS Smart Home Dataset https://casas.wsu.edu/datasets/	Данные датчиков умного дома с аннотацией активностей жильцов.	CSV	Free
2	UCI Activity Recognition (OPPORTUNITY) https://archive.ics.uci.edu/dataset/226/opportunity+activity+recognition	Данные носимых датчиков для распознавания бытовых активностей.	CSV	CC BY
3	Smart Home Energy Dataset (UK-DALE) https://jack-kelly.com/data/	Энергопотребление бытовых приборов по квартирам Великобритании.	HDF5/CSV	CC BY 4.0
4	IoT Device Logs (Kaggle) https://www.kaggle.com/datasets/uciml/iot-intrusion-dataset	Журналы IoT-устройств умного дома с нормальным и аномальным трафиком.	CSV	CC0

Таблица 39. Рекомендуемые источники данных — вариант 39. Умный дом и интернет вещей

Вариант 40. Анализ научных публикаций и цитирований

Задача. Разработать систему интеллектуального поиска и анализа научных публикаций: выявление трендов, рекомендации релевантных статей и построение карты знаний предметной области.

Данные. OpenAlex Dataset; OpenCitations COCI Index; DBLP Computer Science Bibliography; PubMed Articles Dataset

Парадигмы:

Онтология Онтология научной области: понятие → определение → связанные концепты → ключевые работы	Граф знаний Граф цитирований: статья → автор → организация → журнал → ссылки → темы	Семантическая сеть Семантические связи между терминами и концепциями предметной области
--	---	---

Вариант 40. Анализ научных публикаций и цитирований				
№	Название датасета	Описание	Формат	Лицензия
1	OpenAlex Dataset https://openalex.org/	250+ млн работ, авторов и организаций — открытая замена Microsoft Academic Graph.	JSON	ODC-BY
2	OpenCitations COCI Index http://opencitations.net/download#coci	1.3+ млрд DOI-to-DOI цитирований из Crossref — крупнейший открытый индекс цитирований.	JSON	CC0
3	DBLP Computer Science Bibliography https://dblp.org/xml/release/	Полная библиография CS-публикаций с авторами и ссылками.	XML	Open Data Commons

4	PubMed Articles Dataset https://pubmed.ncbi.nlm.nih.gov/download/	Биомедицинские статьи NLM с аннотациями MeSH.	XML/JSON	Public Domain
---	---	---	----------	---------------

Таблица 40. Рекомендуемые источники данных — вариант 40. Анализ научных публикаций и цитирований

Вариант 41. Анализ текста и классификация отзывов

Задача. Построить систему интеллектуального анализа отзывов клиентов: тематическая классификация, определение тональности и выявление ключевых проблем продукта или услуги.

Данные. Amazon Product Reviews (SNAP); Yelp Open Dataset; Trustpilot Reviews (Kaggle); Product Review Sentiment (UCI)

Парадигмы:

Семантическая сеть Сеть понятий: аспект → тональность → ключевые слова → категория жалобы	Продукционные правила Правила маршрутизации: ЕСЛИ тема=доставка И тональность=негативная → отдел логистики	Онтология Онтология аспектов продукта: качество, цена, сервис, доставка, упаковка, соответствие описанию
---	---	--

Вариант 41. Анализ текста и классификация отзывов				
№	Название датасета	Описание	Формат	Лицензия
1	Amazon Product Reviews (SNAP) https://snap.stanford.edu/data/web-Amazon.html	35 млн отзывов Amazon с оценками за 18 лет.	JSON	Free
2	Yelp Open Dataset https://www.yelp.com/dataset	7 млн отзывов на рестораны и бизнес с оценками.	JSON	Free for Research
3	Trustpilot Reviews (Kaggle) https://www.kaggle.com/datasets/thedevastator/trustpilot-reviews-dataset	Отзывы с платформы Trustpilot с тональностью.	CSV	CC0
4	Product Review Sentiment (UCI) https://archive.ics.uci.edu/dataset/228/sentiment+labelled+sentences	3 000 предложений с разметкой позитив/негатив.	TXT	CC BY

Таблица 41. Рекомендуемые источники данных — вариант 41. Анализ текста и классификация отзывов

Вариант 42. Геоинформационный анализ и планирование территорий

Задача. Разработать систему анализа территориального планирования: оценка пригодности земельных участков для строительства, выявление экологических ограничений и оптимизация зонирования.

Данные. OpenStreetMap Data; CORINE Land Cover (Copernicus); US National Land Cover Database; Global Urban Footprint

Парадигмы:

Продукционные правила	Онтология	Генетический алгоритм
------------------------------	------------------	------------------------------

Правила зонирования: ЕСЛИ расстояние_от_реки < 50м ИЛИ уклон > 15° → запрет застройки	Онтология землепользования: зона → ограничения → разрешённые виды деятельности → нормативы	Оптимизация расположения объектов инфраструктуры по множеству критериев
---	--	---

Вариант 42. Геоинформационный анализ и планирование территорий				
№	Название датасета	Описание	Формат	Лицензия
1	OpenStreetMap Data https://www.openstreetmap.org/export	Глобальные геоданные о дорогах, зданиях и землепользовании.	OSM/GeoJSON	ODbL
2	CORINE Land Cover (Copernicus) https://land.copernicus.eu/pan-european/corine-land-cover	Карта землепользования Европы с 44 классами.	Raster/GeoJSON	Free
3	US National Land Cover Database https://www.mrlc.gov/data	Категории землепользования США с 2001 года.	GeoTIFF	Public Domain
4	Global Urban Footprint https://www.dlr.de/eoc/en/desktopdefault.aspx/tabid-9628/16557_read-40454/	Глобальная карта городских территорий на основе спутниковых данных.	GeoTIFF	CC BY

Таблица 42. Рекомендуемые источники данных — вариант 42. Геоинформационный анализ и планирование территорий

Вариант 43. Управление качеством питания и диетология

Задача. Создать интеллектуальную систему персонализированных диетических рекомендаций с учётом состояния здоровья, пищевых предпочтений и нутритивных потребностей.

Данные. USDA FoodData Central; Open Food Facts; Diet and Health Data (Kaggle); Recipe Dataset (RecipeNLG)

Парадигмы:

Продукционные правила Диетические правила: ЕСЛИ диагноз=диабет_2_типа → ограничить ГИ > 55; ЕСЛИ аллергия=глютен → исключить пшеницу	Онтология Онтология питания: продукт → нутриент → суточная норма → заболевание → противопоказания	Семантическая сеть Семантические связи: продукты-заменители, совместимость блюд, кулинарные традиции
--	---	--

Вариант 43. Управление качеством питания и диетология				
№	Название датасета	Описание	Формат	Лицензия
1	USDA FoodData Central https://fdc.nal.usda.gov/download-foods.html	Нутритивный состав 600 000+ продуктов питания США.	CSV/JSON	Public Domain
2	Open Food Facts https://world.openfoodfacts.org/data	3 млн продуктов со всего мира с составом и аллергенами.	CSV/JSON	ODbL
3	Diet and Health Data (Kaggle) https://www.kaggle.com/datasets/niharika41298/nutrition-details-for-most-common-foods-and-drinks	Детальные нутритивные данные для 8 000 продуктов.	CSV	CC0

4	Recipe Dataset (RecipeNLG) https://recipenlg.cs.put.poznan.pl/	2.2 млн рецептов с ингредиентами и инструкциями.	CSV	CC BY-NC-SA
---	--	--	-----	-------------

Таблица 43. Рекомендуемые источники данных — вариант 43. Управление качеством питания и диетология

Вариант 44. Биржевая торговля и портфельный анализ

Задача. Построить систему анализа фондового рынка: формирование инвестиционного портфеля, оценка рыночных рисков и генерация торговых сигналов на основе технических и фундаментальных показателей.

Данные. Yahoo Finance Historical Data; S&P 500 Stocks Dataset (Kaggle); Quandl / Nasdaq Data Link (Free Tier); Fundamentals Dataset (SimFin)

Парадигмы:

Продукционные правила Торговые правила: ЕСЛИ RSI < 30 И MACD пересекает снизу → сигнал на покупку	Фреймы Фрейм ценной бумаги: слоты — тикер, сектор, мультипликаторы P/E, P/B, бета, дивиденды	Генетический алгоритм Эволюционная оптимизация весов активов в портфеле по критерию Шарпа
---	--	---

Вариант 44. Биржевая торговля и портфельный анализ				
№	Название датасета	Описание	Формат	Лицензия
1	Yahoo Finance Historical Data https://finance.yahoo.com/	Котировки акций, ETF и индексов с 1970-х годов.	CSV	Free
2	S&P 500 Stocks Dataset (Kaggle) https://www.kaggle.com/datasets/camnugent/sandp500	Ценовые данные акций S&P 500 за 5 лет с объёмами.	CSV	CC0
3	Quandl / Nasdaq Data Link (Free Tier) https://data.nasdaq.com/	Финансовые и экономические временные ряды.	CSV/JSON	Various
4	Fundamentals Dataset (SimFin) https://simfin.com/data/access/	Фундаментальные финансовые показатели 2 800+ компаний США.	CSV	CC BY-NC-SA

Таблица 44. Рекомендуемые источники данных — вариант 44. Биржевая торговля и портфельный анализ

Вариант 45. Персонализация новостной ленты

Задача. Разработать систему персонализации новостной ленты: профилирование интересов пользователя, кластеризация новостей по темам и борьба с информационными пузырями.

Данные. All the News 2.0 (Kaggle); MIND: Microsoft News Dataset; CC-News Dataset; EventRegistry News (Free API)

Парадигмы:

Семантическая сеть Тематическая сеть: ключевое слово → тема → категория → интересы_пользователя	Граф знаний Граф сущностей: персона → событие → место → организация → связи_между_новостями	Агентная модель Агент-читатель, агент-редактор и агент-разнообразия для балансировки ленты
---	---	--

Вариант 45. Персонализация новостной ленты				
№	Название датасета	Описание	Формат	Лицензия
1	All the News 2.0 (Kaggle) https://www.kaggle.com/davidmcbeaty/all-the-news-20	2.7 млн новостных статей 27 изданий с 2010 по 2020 год.	CSV	CC0
2	MIND: Microsoft News Dataset https://msnews.github.io/	Датасет новостей Microsoft с логами кликов пользователей.	TSV	Microsoft Research
3	CC-News Dataset https://huggingface.co/datasets/cc_news	Новости Common Crawl — миллионы статей за 2016–2019 гг.	JSON	CC0
4	EventRegistry News (Free API) https://eventregistry.org/	Агрегатор новостей с тематической разметкой сущностей.	JSON API	Free Tier

Таблица 45. Рекомендуемые источники данных — вариант 45. Персонализация новостной ленты

Вариант 46. Контроль и аудит цепочки производства продуктов

Задача. Создать систему прослеживаемости и аудита продовольственной цепочки: отслеживание происхождения продукта от поля до прилавка и выявление нарушений стандартов.

Данные. FDA Food Safety Events; Agri-food Trade Statistics (FAO); EU Food Safety Incidents (RASFF); Global Food Prices (WFP)

Парадигмы:

Производственные правила Правила аудита: ЕСЛИ температура при транспортировке > 5°C И продукт=молоко → нарушение холодной цепи	Онтология Онтология цепочки поставок продовольствия: производитель → переработчик → дистрибьютор → ретейлер	Граф знаний Граф прослеживаемости: партия → ингредиенты → поставщики → операции → сертификаты
--	---	---

Вариант 46. Контроль и аудит цепочки производства продуктов				
№	Название датасета	Описание	Формат	Лицензия
1	FDA Food Safety Events https://www.fda.gov/food/recalls-outbreaks-emergencies/food-recalls	Официальные отзывы продуктов питания FDA с 2012 года.	CSV/JSON	Public Domain
2	Agri-food Trade Statistics (FAO) https://www.fao.org/faostat/en/#data	Глобальная торговля сельскохозяйственной продукцией FAO.	CSV	CC BY-NC-SA
3	EU Food Safety Incidents (RASFF) https://webgate.ec.europa.eu/rasff-window/screen/list	RASFF: уведомления о рисках для безопасности пищевых продуктов.	XLSX	Open
4	Global Food Prices (WFP) https://data.humdata.org/dataset/wfp-food-prices	Цены на продовольствие в 98 странах — данные ВПП ООН.	CSV	CC BY

Таблица 46. Рекомендуемые источники данных — вариант 46. Контроль и аудит цепочки производства продуктов

Вариант 47. Поддержка пациентов с хроническими заболеваниями

Задача. Построить систему мониторинга и поддержки пациентов с хроническими заболеваниями (диабет, гипертония): отслеживание показателей, предупреждение обострений и напоминания о приёме препаратов.

Данные. Pima Indians Diabetes Dataset; Hypertension Dataset (Kaggle); PhysioNet MIMIC-III (subset); PPG-DaLiA (UCI)

Парадигмы:

Продукционные правила Правила тревоги: ЕСЛИ глюкоза > 11 ммоль/л ДВА измерения подряд → уведомить врача	Фреймы Фрейм пациента: диагноз, препараты, целевые показатели, ограничения, расписание измерений	Агентная модель Агент-пациент, агент-напоминание, агент-мониторинг и агент-эскалации
---	--	--

Вариант 47. Поддержка пациентов с хроническими заболеваниями				
№	Название датасета	Описание	Формат	Лицензия
1	Pima Indians Diabetes Dataset https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database	768 женщин: глюкоза, инсулин, ИМТ, наличие диабета.	CSV	CC0
2	Hypertension Dataset (Kaggle) https://www.kaggle.com/datasets/prosperchuks/health-dataset	Данные о гипертонии: давление, факторы риска, исходы.	CSV	CC0
3	PhysioNet MIMIC-III (subset) https://physionet.org/content/mimiciii/1.4/	EHR 40 000 пациентов ICU: диагнозы, препараты, лабораторные данные.	CSV	PhysioNet
4	PPG-DaLiA (UCI) https://archive.ics.uci.edu/dataset/495/ppg+dalia	ЭКГ, дыхание, температура и акселерометрия 15 испытуемых с наручного и нагрудного устройств при разных активностях.	CSV	CC BY

Таблица 47. Рекомендуемые источники данных — вариант 47. Поддержка пациентов с хроническими заболеваниями

Вариант 48. Речной и морской транспорт

Задача. Разработать систему оптимизации маршрутов водного транспорта с учётом погодных условий, грузооборота портов и экологических ограничений навигационных зон.

Данные. AIS Ship Tracking Data (Marine Traffic); Global Port Data (World Port Source); Danish Maritime Authority AIS; NOAA Marine Weather Data

Парадигмы:

Продукционные правила Навигационные правила: ЕСЛИ волна > 4м ИЛИ видимость < 0.5 мили → запрет выхода в рейс	Агентная модель Агенты-суда, агенты-порты и агент-диспетчер; обмен сообщениями о позиции и грузе	Генетический алгоритм Оптимизация расписания заходов в порты для минимизации времени в пути и топлива
--	--	---

Вариант 48. Речной и морской транспорт				
№	Название датасета	Описание	Формат	Лицензия
1	AIS Ship Tracking Data (Marine Traffic) https://www.marinetraffic.com/en/p/ais-historical-data	AIS-данные о позициях судов по всему миру.	CSV	Commercial / Research
2	Global Port Data (World Port Source) https://www.worldportsource.com/	Данные о 5 000+ портах: координаты, инфраструктура, грузооборот.	CSV	Free
3	Danish Maritime Authority AIS https://www.dma.dk/safety-at-sea/navigational-information/ais-data	Открытые AIS-данные Дании за несколько лет.	CSV	Open
4	NOAA Marine Weather Data https://tidesandcurrents.noaa.gov/	Метеоданные и приливы из морских метеостанций NOAA.	CSV/API	Public Domain

Таблица 48. Рекомендуемые источники данных — вариант 48. Речной и морской транспорт

Вариант 49. Педагогическая диагностика и адаптивное обучение

Задача. Создать систему адаптивного тестирования и диагностики пробелов в знаниях студентов: построение персонального профиля компетенций и рекомендации траектории обучения.

Данные. Open University Learning Analytics (OULAD); Junyi Academy Math Learning; EdNet: Large-Scale Hierarchical Dataset; ASSISTments Math Dataset

Парадигмы:

Продукционные правила Правила диагностики: ЕСЛИ ошибок_в_теме_A > 40% И тема_A предшествует теме_Б → назначить повторение A	Фреймы Фрейм компетенции: слоты — предмет, тема, уровень владения, связанные темы, рекомендуемые ресурсы	Граф знаний Граф знаний курса: тема → подтема → понятие → задание → уровень_сложности → предпосылки
---	--	---

Вариант 49. Педагогическая диагностика и адаптивное обучение				
№	Название датасета	Описание	Формат	Лицензия
1	Open University Learning Analytics (OULAD) https://analyse.kmi.open.ac.uk/open_dataset	Данные о 32 000 студентах: активность, результаты, отчисление.	CSV	CC BY 4.0
2	Junyi Academy Math Learning https://www.kaggle.com/datasets/junyiacademy/learning-activity-public-dataset-by-junyi-academy	25 млн записей о решении математических задач школьниками.	CSV	CC BY-NC-SA
3	EdNet: Large-Scale Hierarchical Dataset https://github.com/riid/ednet	95 млн взаимодействий студентов с образовательной платформой.	CSV	CC BY-NC
4	ASSISTments Math Dataset https://sites.google.com/site/assistmentsdata/	Ответы школьников на задачи по математике с подсказками.	CSV	Free

Таблица 49. Рекомендуемые источники данных — вариант 49. Педагогическая диагностика и адаптивное обучение

Вариант 50. Управление дорожной инфраструктурой

Задача. Построить систему интеллектуального управления дорожным движением: адаптивная работа светофоров, перераспределение потоков при инцидентах и приоритет для экстренных служб.

Данные. PeMS: California Traffic Data; TomTom Traffic Stats (Open); Uber Movement (Speeds); OpenTraffic (OSM-based)

Парадигмы:

Продукционные правила Правила адаптации: ЕСЛИ очередь > 15 авто И направление приоритетное → продлить зелёный на 20с	Агентная модель Агенты-перекрёстки, взаимодействующие с агентом-координатором коридора	Онтология Онтология дорожной сети: узел → дуга → ограничения → категория дороги → трафик
--	--	--

Вариант 50. Управление дорожной инфраструктурой				
№	Название датасета	Описание	Формат	Лицензия
1	PeMS: California Traffic Data https://pems.dot.ca.gov/	Интенсивность трафика с датчиков Калифорнии в реальном времени.	CSV	Public Domain
2	TomTom Traffic Stats (Open) https://www.tomtom.com/traffic-index/	Открытые агрегированные данные о пробках в мировых городах.	CSV/JSON	Free
3	Uber Movement (Speeds) https://movement.uber.com/	Скорости движения по улицам городов мира — данные Uber.	CSV	CC BY-NC
4	OpenTraffic (OSM-based) https://opentraffic.io/	Анонимные данные о скорости и интенсивности трафика.	JSON	CC BY

Таблица 50. Рекомендуемые источники данных — вариант 50. Управление дорожной инфраструктурой

Вариант 51. Выявление плагиата и академической нечестности

Задача. Разработать систему обнаружения плагиата в студенческих работах и академических публикациях: семантическое сравнение, выявление парафраза и структурных заимствований.

Данные. PAN Plagiarism Detection Dataset; SNLI / MultiNLI (Paraphrase); Quora Question Pairs; Wikipedia Corpus

Парадигмы:

Семантическая сеть Сеть синонимов и перефразировок для обнаружения скрытых заимствований	Продукционные правила Правила классификации: ЕСЛИ совпадение > 30% И источник_не_указан → вероятный плагиат	Граф знаний Граф документов: текст → предложение → n-gram → источник → авторство
--	---	--

Вариант 51. Выявление плагиата и академической нечестности				
№	Название датасета	Описание	Формат	Лицензия
1	PAN Plagiarism Detection Dataset https://pan.webis.de/data.html	Коллекции PAN для соревнований по обнаружению плагиата.	XML	CC BY 4.0
2	SNLI / MultiNLI (Paraphrase) https://nlp.stanford.edu/projects/snli/	570 000 пар предложений с разметкой логических отношений.	JSON	CC BY-SA
3	Quora Question Pairs https://www.kaggle.com/c/quora-question-pairs/data	404 000 пар вопросов с разметкой семантической эквивалентности.	CSV	CC0
4	Wikipedia Corpus https://dumps.wikimedia.org/	Дамп Википедии — эталонная база для сравнения текстов.	XML	CC BY-SA

Таблица 51. Рекомендуемые источники данных — вариант 51. Выявление плагиата и академической нечестности

Вариант 52. Анализ дефектов в производстве электроники

Задача. Создать систему контроля качества производства электронных компонентов: классификация типов дефектов по данным тестирования, прогнозирование отказов и оптимизация технологических параметров.

Данные. SECOM Manufacturing Dataset (UCI); PCB Defect Dataset (Kaggle); AITEX Fabric Defect Dataset; Steel Plates Faults (UCI)

Парадигмы:

Продукционные правила Правила разбраковки: ЕСЛИ сопротивление вне $\pm 5\%$ И температурный дрейф $> 2\%$ → отклонение	Фреймы Фрейм дефекта: тип, компонент, параметры, вероятная причина, рекомендация по исправлению	Генетический алгоритм Оптимизация параметров техпроцесса (температура пайки, время, давление) для снижения брака
--	---	--

Вариант 52. Анализ дефектов в производстве электроники				
№	Название датасета	Описание	Формат	Лицензия
1	SECOM Manufacturing Dataset (UCI) https://archive.ics.uci.edu/dataset/179/secom	1 567 образцов с 590 сигналами полупроводникового производства.	CSV	CC BY
2	PCB Defect Dataset (Kaggle) https://www.kaggle.com/datasets/akhatova/pcb-defects	Изображения печатных плат с 6 типами дефектов.	JPEG/XML	CC0
3	AITEX Fabric Defect Dataset https://www.aitex.es/afid/	Изображения тканей с дефектами для задач контроля качества.	PNG	Free for Research
4	Steel Plates Faults (UCI) https://archive.ics.uci.edu/dataset/198/steel+plates+faults	1 941 стальная плита, 27 атрибутов, 7 типов дефектов.	CSV	CC BY

Таблица 52. Рекомендуемые источники данных — вариант 52. Анализ дефектов в производстве электроники

Вариант 53. Система ответов на вопросы и чат-поддержка

Задача. Построить интеллектуальную систему ответов на вопросы пользователей в предметной области технической поддержки: классификация обращений, поиск ответов в базе знаний и эскалация.

Данные. Ubuntu Dialogue Corpus; StackOverflow Questions (Kaggle); SQuAD 2.0 Reading Comprehension; Customer Support on Twitter (Kaggle)

Парадигмы:

Семантическая сеть Тезаурус предметной области для сопоставления вопроса с ответом без точного совпадения	Граф знаний Граф базы знаний: симптом → причина → решение → инструкция → связанные_вопросы	Продукционные правила Правила маршрутизации: ЕСЛИ тема=«оплата» И статус=«не_решено» И попытки > 2 → живой оператор
---	--	---

Вариант 53. Система ответов на вопросы и чат-поддержка				
№	Название датасета	Описание	Формат	Лицензия
1	Ubuntu Dialogue Corpus https://www.kaggle.com/datasets/rtatman/ubuntu-dialogue-corpus	930 000 диалогов технической поддержки Ubuntu.	CSV	CC BY
2	StackOverflow Questions (Kaggle) https://www.kaggle.com/datasets/stackoverflow/stackoverflow	Вопросы и ответы StackOverflow с тегами и рейтингами.	CSV	CC BY-SA
3	SQuAD 2.0 Reading Comprehension https://rajpurkar.github.io/SQuAD-explorer/	150 000 пар вопрос-ответ по Википедии.	JSON	CC BY-SA
4	Customer Support on Twitter (Kaggle) https://www.kaggle.com/datasets/thoughtvector/customer-support-on-twitter	3 млн твитов поддержки крупных брендов.	CSV	CC0

Таблица 53. Рекомендуемые источники данных — вариант 53. Система ответов на вопросы и чат-поддержка

Вариант 54. Пожарная безопасность и предотвращение возгораний

Задача. Разработать систему раннего прогнозирования и мониторинга пожарной опасности: оценка риска возгорания в зданиях и на природных территориях, маршрутизация аварийных служб.

Данные. NASA FIRMS: Fire Information (MODIS); Canadian Wildfire Database; USFS Wildfire Occurrence Data; Fire Incidents (Kaggle)

Парадигмы:

Продукционные правила Правила риска: ЕСЛИ температура > 35°C И влажность < 20% И скорость ветра > 40 км/ч → высокий риск пожара	Онтология Онтология пожарной безопасности: объект → зона риска → фактор → мероприятие → норматив	Агентная модель Агенты-датчики дыма, агент-пожарная_часть, агент-эвакуации; координация реагирования
---	--	--

Вариант 54. Пожарная безопасность и предотвращение возгораний				
№	Название датасета	Описание	Формат	Лицензия
1	NASA FIRMS: Fire Information (MODIS) https://firms.modaps.eosdis.nasa.gov/	Глобальные данные о лесных пожарах из спутниковых наблюдений.	CSV/Shapefile	Public Domain
2	Canadian Wildfire Database https://cwfis.cfs.nrcan.gc.ca/datamart/datarequest/nfdbPoint	390 000+ лесных пожаров в Канаде с 1950 по 2021 год.	GeoJSON/CSV	Open Government
3	USFS Wildfire Occurrence Data https://www.fs.usda.gov/rds/archive/Catalog/RDS-2013-0009.6	2.3 млн лесных пожаров США 1992–2020 гг.	SQLite	Public Domain
4	Fire Incidents (Kaggle) https://www.kaggle.com/datasets/ratman/140-million-rows-of-fire-incidents	Журналы пожарных инцидентов сан-францисских пожарных.	CSV	CC0

Таблица 54. Рекомендуемые источники данных — вариант 54. Пожарная безопасность и предотвращение возгораний

Вариант 55. Анализ финансовой отчётности компаний

Задача. Создать экспертную систему для анализа финансовой отчётности предприятий: оценка платёжеспособности, прибыльности, выявление признаков финансовых манипуляций.

Данные. 200+ Financial Indicators of US Stocks (Kaggle); SEC EDGAR Financial Statements; Company Bankruptcy Prediction (Kaggle); Accounting Fraud Dataset (Bao et al., 2020, JAR)

Парадигмы:

Продукционные правила Правила оценки: ЕСЛИ текущая_ликвидность < 1 И долг/EBITDA > 4 → признаки неплатёжеспособности	Онтология Онтология финансовой отчётности: статья → финансовый_показатель → норматив → интерпретация	Логика (Prolog) Логический вывод по признакам Бениша и Альтмана для обнаружения искажений
--	--	---

Вариант 55. Анализ финансовой отчётности компаний				
№	Название датасета	Описание	Формат	Лицензия
1	200+ Financial Indicators of US Stocks (Kaggle) https://www.kaggle.com/datasets/cnic92/200-financial-indicators-of-us-stocks-20142018	Более 200 финансовых показателей 4000+ компаний США за 2014-2018 гг. с меткой роста цены акции.	CSV	CC0
2	SEC EDGAR Financial Statements https://www.sec.gov/search-filings	Официальные финансовые отчёты всех публичных компаний США.	XBRL/JSON	Public Domain
3	Company Bankruptcy Prediction (Kaggle) https://www.kaggle.com/datasets/fedesoriano/company-bankruptcy-prediction	6819 тайваньских компаний, 96 показателей, метка банкротства (1999-2009 гг.).	CSV	CC0

4	Accounting Fraud Dataset (Bao et al., 2020, JAR) https://github.com/JarFraud/FraudDetection	Репликационный пакет к статье JAR (2020): коэффициенты и метки SEC AAER для выявления фальсификаций отчётности.	CSV	CC0
---	--	---	-----	-----

Таблица 55. Рекомендуемые источники данных — вариант 55. Анализ финансовой отчётности компаний

Вариант 56. Управление отходами и раздельный сбор мусора

Задача. Построить систему оптимизации раздельного сбора и маршрутизации вывоза бытовых отходов в городе: прогнозирование заполнения контейнеров и оптимизация маршрутов мусоровозов.

Данные. Smart Waste Management Dataset (Kaggle); Recycling Rates by Country (Our World in Data); SF Environment Waste Diversion (data.gov); European Waste Statistics (Eurostat)

Парадигмы:

Продукционные правила Правила вывоза: ЕСЛИ уровень_наполнения > 80% → добавить точку в маршрут; ЕСЛИ праздник → удвоить частоту	Агентная модель Агенты-контейнеры, агенты-мусоровозы и агент-диспетчер; динамическое планирование маршрутов	Генетический алгоритм Оптимизация ежедневных маршрутов по критериям расстояния и времени
---	---	--

Вариант 56. Управление отходами и раздельный сбор мусора				
№	Название датасета	Описание	Формат	Лицензия
1	Smart Waste Management Dataset (Kaggle) https://www.kaggle.com/datasets/shashanksai/smart-waste-management	Данные IoT-датчиков уровня заполнения контейнеров.	CSV	CC0
2	Recycling Rates by Country (Our World in Data) https://ourworldindata.org/plastic-pollution	Статистика переработки и утилизации ТБО по странам.	CSV	CC BY
3	SF Environment Waste Diversion (data.gov) https://data.sfgov.org/City-Infrastructure/Recology-Complaints/fkm4-xpgh	Данные сортировки и жалоб по вывозу мусора Сан-Франциско.	CSV	Public Domain
4	European Waste Statistics (Eurostat) https://ec.europa.eu/eurostat/web/waste	Данные о производстве и переработке отходов по странам ЕС.	CSV	CC BY

Таблица 56. Рекомендуемые источники данных — вариант 56. Управление отходами и раздельный сбор мусора

Вариант 57. Анализ биомедицинских данных и клинических исследований

Задача. Разработать систему поддержки клинических исследований: структурирование данных пациентов, выявление паттернов в клинических показателях и формирование гипотез об эффективности лечения.

Данные. PhysioNet MIMIC-IV; ClinicalTrials.gov Dataset; eICU Collaborative Research Database; TCGA Cancer Genomics Data

Парадигмы:

Онтология Клиническая онтология на основе SNOMED CT: диагноз → процедура → препарат → показатель	Граф знаний Граф пациент → визит → диагноз → назначение → результат → побочный_эффект	Продукционные правила Правила включения/исключения в исследование; интерпретация лабораторных отклонений
--	---	--

Вариант 57. Анализ биомедицинских данных и клинических исследований				
№	Название датасета	Описание	Формат	Лицензия
1	PhysioNet MIMIC-IV https://physionet.org/content/mimiciv/2.2/	EHR 65 000+ пациентов Beth Israel Deaconess Medical Center.	CSV	PhysioNet
2	ClinicalTrials.gov Dataset https://clinicaltrials.gov/ct2/resources/download	450 000+ клинических исследований с условиями и результатами.	XML/JSON	Public Domain
3	eICU Collaborative Research Database https://physionet.org/content/eicu-crd/2.0/	Данные 200 000 пациентов отделений интенсивной терапии США.	CSV	PhysioNet
4	TCGA Cancer Genomics Data https://portal.gdc.cancer.gov/	Геномные и клинические данные 11 000 онкологических пациентов.	CSV/JSON	Open Access

Таблица 57. Рекомендуемые источники данных — вариант 57. Анализ биомедицинских данных и клинических исследований

Вариант 58. Онлайн-образование и МООС-платформы

Задача. Создать систему прогнозирования успешности прохождения онлайн-курсов и снижения оттока: выявление студентов в группе риска и персонализация вмешательств для поддержки.

Данные. KDD Cup 2015: MOOC Dropout; HarvardX/MITx MOOC Dataset; Coursera Course Reviews; Open University Learning Analytics

Парадигмы:

Продукционные правила Правила выявления риска: ЕСЛИ активность < 1 раза/неделю И просмотрено < 30% контента → риск отчисления	Фреймы Фрейм студента: курс, прогресс, паттерн активности, предпочтительный формат, результаты тестов	Логика (Prolog) Логический вывод о выполнении предварительных требований и допуске к следующему модулю
---	---	--

Вариант 58. Онлайн-образование и МООС-платформы				
№	Название датасета	Описание	Формат	Лицензия
1	KDD Cup 2015: MOOC Dropout https://www.kaggle.com/c/kdd-cup-2015/data	Данные о активности на МООС-платформе и отчислении студентов.	CSV	CC0
2	HarvardX/MITx MOOC Dataset https://dataverse.harvard.edu/dataset.xhtml?persistentId=doi:10.7910/DVN/26147	Данные о прохождении первых онлайн-	CSV	CC0

		курсов EdX (2012–2013).		
3	Coursera Course Reviews https://www.kaggle.com/datasets/imuhammad/course-reviews-on-coursera	88 000 отзывов на курсы Coursera с оценками.	CSV	CC0
4	Open University Learning Analytics https://analyse.kmi.open.ac.uk/open_dataset	Поведенческие данные 32 000 студентов Открытого университета.	CSV	CC BY 4.0

Таблица 58. Рекомендуемые источники данных — вариант 58. Онлайн-образование и MOOC-платформы

Вариант 59. Туристическая индустрия и бронирование отелей

Задача. Построить систему управления доходностью отеля: прогнозирование спроса, динамическое ценообразование номеров и оптимизация политики отмены бронирований.

Данные. Hotel Booking Demand Dataset; Trivago Hotel Click Dataset; Expedia Hotel Recommendations (Kaggle); STR Benchmarking Data (Sample)

Парадигмы:

Продукционные правила Ценовые правила: ЕСЛИ загрузка > 85% И до заезда < 7 дней → повысить цену на 20%	Фреймы Фрейм бронирования: тип номера, канал продажи, сегмент гостя, длина пребывания, доп. услуги	Генетический алгоритм Оптимизация сезонного прайса по комбинациям дата/тип_номера/канал для максимизации RevPAR
--	--	---

Вариант 59. Туристическая индустрия и бронирование отелей				
№	Название датасета	Описание	Формат	Лицензия
1	Hotel Booking Demand Dataset https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand	119 000 бронирований двух отелей Португалии с признаками отмены.	CSV	CC0
2	Trivago Hotel Click Dataset https://recsys.trivago.cloud/challenge/dataset/	Взаимодействия пользователей с отелями на Trivago.	CSV	Research
3	Expedia Hotel Recommendations (Kaggle) https://www.kaggle.com/c/expedia-hotel-recommendations/data	37 млн поисков и бронирований на Expedia.	CSV	CC0
4	STR Benchmarking Data (Sample) https://www.kaggle.com/datasets/SauravMaheshkar/hotel-revenue-data	Данные выручки и загрузки отеля для анализа RevPAR.	XLSX	CC0

Таблица 59. Рекомендуемые источники данных — вариант 59. Туристическая индустрия и бронирование отелей

Вариант 60. Мониторинг шума и акустическая экология города

Задача. Разработать систему мониторинга и классификации источников городского шума: картирование акустической обстановки, выявление нарушителей шумовых норм и рекомендации по озеленению и планировке.

Данные. Sound of New York City (SONYC); Urban Sound Dataset (UrbanSound8K); NYC 311 Noise Complaints; ESC-50: Environmental Sounds

Парадигмы:

Продукционные правила Правила нарушений: ЕСЛИ уровень_шума > 55 дБ(А) ночью В жилой_зоне → составить акт нарушения	Онтология Онтология акустической экологии: источник → тип → зона → норматив → воздействие → мероприятие	Граф знаний Граф городской среды: точка_измерения → источник_шума → маршрут → жалоба → решение
---	---	---

Вариант 60. Мониторинг шума и акустическая экология города				
№	Название датасета	Описание	Формат	Лицензия
1	Sound of New York City (SONYC) https://zenodo.org/record/3966543	Аудиозаписи городского шума 23 классов из Нью-Йорка.	MP3/CSV	CC BY 4.0
2	Urban Sound Dataset (UrbanSound8K) https://urbansounddataset.weebly.com/urbansound8k.html	8 732 аудиоклипа 10 категорий городского шума.	WAV/CSV	CC BY-NC
3	NYC 311 Noise Complaints https://data.cityofnewyork.us/Social-Services/311-Service-Requests-from-2010-to-Present/erm2-nwe9	23 млн обращений 311 Нью-Йорка, включая жалобы на шум.	CSV	Public Domain
4	ESC-50: Environmental Sounds https://github.com/karolpiczak/ESC-50	2 000 аудиозаписей 50 классов окружающих звуков.	WAV/CSV	CC BY-NC

Таблица 60. Рекомендуемые источники данных — вариант 60. Мониторинг шума и акустическая экология города

Примечание: Студент вправе использовать альтернативные датасеты по согласованию с преподавателем. Обязательное условие — открытая лицензия, допускающая учебное использование (CC0, CC BY, Public Domain или Research с бесплатной регистрацией). Минимальный объем датасета: 500 записей.