

Раздел 1. Цель работы

Цель работы - реализовать сбор данных из источника, выбранного на первом этапе проекта, выполнить их разведочный анализ (Exploratory Data Analysis, EDA) и сформировать представление о структуре и качестве данных для дальнейшего использования в прототипе интеллектуальной системы предиктивного обслуживания.

Задачи работы:

1. установить и настроить инструментарий для работы с данными;
2. реализовать загрузку набора данных из выбранного источника и проверить его целостность;
3. провести первичный анализ данных: структура, типы полей, пропуски, дубликаты, распределения, выбросы, связи между признаками;
4. проверить согласованность целевых меток и соответствие данных документированным условиям возникновения отказов;
5. сделать выводы о качестве данных и сформировать план очистки и трансформации.

Объект анализа определён на первом этапе проекта: набор данных AI4I 2020 Predictive Maintenance Dataset (UCI Machine Learning Repository, идентификатор 601, лицензия CC BY 4.0). Набор описывает работу фрезерного станка и содержит показания датчиков, класс качества обрабатываемого изделия и метки пяти типов отказа. Выбор обоснован в отчёте по практической работе № 1 (раздел 3.2).

Раздел 2. Инструментарий

Анализ выполнен исключительно средствами свободного программного обеспечения, что соответствует ограничениям курса. Состав использованных средств приведён в таблице 1.

Таблица 1 - Используемое программное обеспечение и библиотеки

Наименование	Версия	Назначение	Лицензия
Python	3.12.3	Язык программирования, среда выполнения анализа	PSF License
pandas	3.0.2	Загрузка CSV, работа с табличными данными, агрегирование, сводные таблицы	BSD-3-Clause
NumPy	2.4.4	Векторные вычисления, расчёт производных признаков	BSD-3-Clause
Matplotlib	3.10.8	Построение гистограмм, диаграмм размаха, диаграмм рассеяния, карты заполненности	PSF-based
Seaborn	0.13.2	Вспомогательные статистические визуализации	BSD-3-Clause
SciPy	1.17.1	Расчёт статистических характеристик распределений	BSD-3-Clause
Jupyter Notebook	7.x	Интерактивная среда проведения анализа	BSD-3-Clause

Установка окружения выполняется командой:

```
pip install jupyter pandas numpy matplotlib seaborn scipy openpyxl
```

Библиотека `missingno`, упомянутая в методических указаниях, в работе не применялась: карта заполненности данных построена средствами `Matplotlib`, поскольку набор не содержит пропусков и специализированная визуализация не требуется.

Загрузка данных реализована средствами `pandas`. Файл сохраняется в кодировке UTF-8 с BOM, поэтому при чтении указывается кодировка `utf-8-sig`, иначе имя первого столбца читается с искажением:

```
import pandas as pd

df = pd.read_csv('data/ai4i2020.csv', encoding='utf-8-sig')
print(df.shape)           # (10000, 14)
print(df.dtypes)
df.head()
```

Раздел 3. Структура данных

3.1. Общая характеристика набора

Набор данных представлен одним файлом `ai4i2020.csv` объёмом около 510 КБ. После загрузки в оперативной памяти объект `DataFrame` занимает около 1963 КБ. Набор содержит 10 000 записей и 14 полей; каждая запись

соответствует одному наблюдению за состоянием станка. Идентификатор записи UDI принимает 10 000 уникальных значений, идентификатор изделия Product ID - также 10 000 уникальных значений, то есть каждая строка описывает обработку отдельного изделия.

Состав и назначение полей приведены в таблице 2. Роль поля указана применительно к задаче проекта: предикторы используются в условиях производственных правил, целевые поля - для проверки корректности вывода, служебные поля в анализе не участвуют.

Таблица 2 - Описание полей набора данных

Поле	Тип	Ед. изм.	Описание	Роль
UDI	int64	-	Порядковый идентификатор записи, значения от 1 до 10 000	Служебное
Product ID	object	-	Идентификатор изделия: буква класса качества и серийный номер	Служебное
Type	object	-	Класс качества изделия: L - низкий, M - средний, H - высокий	Предиктор (категориальный)
Air temperature [K]	float64	К	Температура окружающего воздуха в рабочей зоне	Предиктор
Process temperature [K]	float64	К	Температура технологического процесса	Предиктор
Rotational speed [rpm]	int64	об/мин	Частота вращения шпинделя	Предиктор
Torque [Nm]	float64	Н·м	Крутящий момент на приводе	Предиктор
Tool wear [min]	int64	мин	Накопленный износ режущего инструмента	Предиктор
Machine failure	int64	-	Обобщённый признак отказа станка в данном наблюдении	Целевое (основное)
TWF	int64	-	Отказ по износу инструмента (tool wear failure)	Целевое (подтип)
HDF	int64	-	Отказ из-за нарушения теплоотвода (heat dissipation failure)	Целевое (подтип)
PWF	int64	-	Отказ по мощности привода (power failure)	Целевое (подтип)
OSF	int64	-	Отказ вследствие перегрузки (overstrain failure)	Целевое (подтип)
RNF	int64	-	Случайный отказ, не связанный с режимами работы	Целевое (подтип)

Типы полей определены библиотекой pandas корректно: числовые признаки распознаны как int64 и float64, категориальные - как object. Приведения типов на этапе загрузки не потребовалось; перевод поля Type в

тип category запланирован на этапе трансформации для сокращения объёма памяти.

3.2. Статистические характеристики числовых признаков

Описательные статистики пяти числовых предикторов приведены в таблице 3. Помимо стандартного набора, рассчитаны межквартильный размах (IQR), границы выбросов по правилу полутора межквартильных размахов, коэффициенты асимметрии и эксцесса.

Таблица 3 - Статистические характеристики числовых признаков

Показатель	Т воздуха, К	Т процесса, К	Обороты, об/мин	Момент, Н·м	Износ, мин
Число значений	10 000	10 000	10 000	10 000	10 000
Уникальных значений	93	82	941	577	246
Среднее	300,00	310,01	1538,78	39,99	107,95
Медиана	300,10	310,10	1503,00	40,10	108,00
Стандартное отклонение	2,00	1,48	179,28	9,97	63,65
Минимум	295,30	305,70	1168,00	3,80	0,00
Первый квартиль	298,30	308,80	1423,00	33,20	53,00
Третий квартиль	301,50	311,10	1612,00	46,80	162,00
Максимум	304,50	313,80	2886,00	76,60	253,00
Межквартильный размах	3,20	2,30	189,00	13,60	109,00
Асимметрия	0,11	0,02	1,99	-0,01	0,03
Эксцесс	-0,84	-0,50	7,39	-0,01	-1,17
Отрицательных значений	0	0	0	0	0

Значения признаков физически непротиворечивы: отрицательных величин нет, температуры находятся в правдоподобном для цеха диапазоне (от 295,3 до 304,5 К для воздуха, то есть примерно от 22 до 31 градуса Цельсия), износ инструмента изменяется от нуля до 253 минут. Нулевое значение износа встречается в 120 записях и соответствует началу эксплуатации нового инструмента, то есть не является пропуском, закодированным нулём.

Признаки различаются по форме распределения. Температуры и крутящий момент распределены близко к нормальному закону (асимметрия не превышает 0,11 по модулю). Износ инструмента распределён практически равномерно (эксцесс -1,17), что отражает равномерный съём наблюдений на протяжении всего цикла работы инструмента. Частота вращения имеет выраженную правостороннюю асимметрию (1,99) и тяжёлый правый хвост (эксцесс 7,39), поскольку рассчитывалась из условия постоянной мощности привода и обратно связана с крутящим моментом. Гистограммы распределений приведены на рисунке 1, диаграммы размаха - на рисунке 2.




Рисунок 1 - Гистограммы распределений числовых признаков




Рисунок 2 - Диаграммы размаха числовых признаков

Раздел 4. Анализ качества данных

4.1. Анализ пропусков

Проверка пропусков выполнена методом `isnull` с последующим суммированием по столбцам:

```
na = df.isnull().sum()
print(na[na > 0])          # пустой результат
print(df.isnull().sum().sum()) # 0
```

Пропущенные значения в наборе отсутствуют полностью: ни одно из 14 полей не содержит ни одного пропуска, доля заполненности составляет 100 % по всем 140 000 ячейкам. Карта заполненности данных приведена на рисунке 3; сплошная заливка по всей площади подтверждает отсутствие пропусков.




Рисунок 3 - Карта заполненности данных

Отдельно проверено, не закодированы ли пропуски специальными значениями. Нули встречаются только в поле износа инструмента (120 записей) и в бинарных полях меток, где ноль является содержательным значением. Значений-заполнителей вида -1, 999 или пустых строк в категориальных полях не обнаружено. Таким образом, обработка пропусков на этапе очистки не требуется, что существенно упрощает подготовку данных.

4.2. Анализ дубликатов

Проверка выполнена в трёх вариантах: полное совпадение строк, совпадение по всем полям без идентификаторов и совпадение только по показаниям датчиков.

```

print(df.duplicated().sum()) # 0
print(df.drop(columns=['UDI', 'Product ID']).duplicated().sum()) # 0
sens = ['Air temperature [K]', 'Process temperature [K]',
        'Rotational speed [rpm]', 'Torque [Nm]', 'Tool wear [min]']
print(df[sens].duplicated().sum()) # 0

```

Дубликаты отсутствуют во всех трёх постановках. Совпадений даже по пяти показаниям датчиков нет, что объясняется непрерывным характером измеряемых величин. Проверена также согласованность идентификаторов: первая буква поля Product ID совпадает со значением поля Type во всех 10 000 записях, то есть противоречий между полями нет.

4.3. Анализ выбросов

Выбросы выявлялись по правилу межквартильного размаха: значение считается выбросом, если оно выходит за границы первого квартиля минус полтора IQR и третьего квартиля плюс полтора IQR. Результаты приведены в таблице 4.

Таблица 4 - Результаты поиска выбросов по правилу межквартильного размаха

Признак	Нижняя граница	Верхняя граница	Выбросов снизу	Выбросов сверху	Доля, %
Температура воздуха, К	293,50	306,30	0	0	0,00
Температура процесса, К	305,35	314,55	0	0	0,00
Частота вращения, об/мин	1139,50	1895,50	0	418	4,18
Крутящий момент, Н·м	12,80	67,20	28	41	0,69
Износ инструмента, мин	-110,50	325,50	0	0	0,00

Формально выбросы обнаружены только у двух признаков - частоты вращения (418 записей, 4,18 %) и крутящего момента (69 записей, 0,69 %). Однако их удаление недопустимо, и это принципиальный вывод анализа. Проверка связи выбросов с целевой меткой показала следующее: среди 69 записей с аномальным крутящим моментом отказ зафиксирован в 62 случаях, то есть 89,9 %; среди 418 записей с аномальной частотой вращения отказ зафиксирован в 35 случаях, то есть 8,4 % при среднем уровне по набору 3,39 %.

Иначе говоря, статистические выбросы являются не шумом измерений, а именно теми режимами работы, которые приводят к отказу оборудования. Удаление таких записей уничтожило бы значительную часть полезного сигнала. Высокие значения частоты вращения объясняются обратной зависимостью от крутящего момента при примерно постоянной мощности привода, а не ошибками датчика. Соответственно, на этапе очистки выбросы сохраняются, а правило межквартильного размаха используется не для фильтрации, а как вспомогательный индикатор нештатных режимов.

4.4. Анализ связей между признаками

Матрица парных коэффициентов корреляции Пирсона приведена на рисунке 4. Выявлены две сильные линейные связи.

- температура процесса и температура воздуха: коэффициент 0,876. Связь детерминирована технологически - температура процесса формируется как температура воздуха плюс примерно 10 К. Разность этих величин колеблется в узком диапазоне от 7,6 до 12,1 К при среднем значении 10,0 К и стандартном отклонении 1,0 К;
- крутящий момент и частота вращения: коэффициент -0,875 (коэффициент ранговой корреляции Спирмена -0,916). Связь отражает работу привода при примерно постоянной мощности: чем выше момент, тем ниже обороты.

Остальные пары признаков практически некоррелированы: модуль коэффициента не превышает 0,03. Наличие двух сильных связей означает мультиколлинеарность и имеет прямое практическое следствие для проекта: содержательной величиной является не каждый признак по отдельности, а их комбинация - разность температур и мощность привода. Именно эти производные величины фигурируют в условиях производственных правил, сформулированных на первом этапе.




Рисунок 4 - Матрица парных корреляций числовых признаков

Совместное распределение частоты вращения и крутящего момента с выделением записей с отказом приведено на рисунке 5. Точки образуют гиперболическую полосу постоянной мощности; записи с отказом сосредоточены на её границах - в области высокого момента при низких оборотах и в области предельно низкого момента при высоких оборотах.




Рисунок 5 - Совместное распределение оборотов и момента с выделением отказов

4.5. Анализ категориальных и целевых признаков

Категориальный признак *Туре* принимает три значения. Фактическое распределение: L - 6000 записей (60,00 %), М - 2997 записей (29,97 %), Н - 1003 записи (10,03 %). Здесь обнаружено расхождение с документацией набора данных, где заявлено соотношение классов 50 / 30 / 20 %. Фактическая доля класса L завышена на 10 процентных пунктов, доля класса Н занижена на такую же величину. Расхождение зафиксировано как особенность набора; при интерпретации результатов по классу Н следует учитывать, что он представлен наименьшим числом наблюдений.

Распределение целевых меток приведено в таблице 5.

Таблица 5 - Распределение целевых меток

Метка	Содержание	Число записей	Доля, %
Machine failure	Обобщённый признак отказа	339	3,39
TWF	Отказ по износу инструмента	46	0,46
HDF	Нарушение теплоотвода	115	1,15
PWF	Отказ по мощности привода	95	0,95
OSF	Перегрузка	98	0,98
RNF	Случайный отказ	19	0,19

Набор характеризуется выраженным дисбалансом классов: отказы составляют 3,39 % записей, соотношение классов примерно 1 к 28. Наиболее частым типом отказа является нарушение теплоотвода (115 случаев), наиболее редким - случайный отказ (19 случаев). Распределение категориальных и целевых признаков приведено на рисунке 6.




Рисунок 6 - Распределение класса качества изделия и типов отказа

Доля отказов существенно зависит от класса качества изделия: для класса L она составляет 3,92 % (235 отказов из 6000), для класса М - 2,77 % (83 из 2997), для класса Н - 2,09 % (21 из 1003). Убывание доли отказов с ростом класса качества согласуется с заложеной в набор логикой: для изделий более высокого класса допустимый предел перегрузки выше. Распределение типов отказа по классам приведено в таблице 6.

Таблица 6 - Распределение типов отказа по классам качества изделия

Класс	Записей	Отказов	Доля отказов, %	TWF	HDF	PWF	OSF	RNF
L	6000	235	3,92	25	76	59	87	13
М	2997	83	2,77	14	31	31	9	2
Н	1003	21	2,09	7	8	5	2	4

Обращает на себя внимание распределение отказов по перегрузке: из 98 случаев 87 приходятся на класс L и лишь 2 на класс Н, что прямо следует из различия пороговых значений для разных классов.

4.6. Проверка согласованности целевых меток

Поскольку в проекте метки используются для проверки корректности базы производственных правил, отдельно проверена их внутренняя непротиворечивость. Выявлены два дефекта разметки.

1. В 9 записях обобщённая метка Machine failure равна единице, но ни один из пяти подтипов отказа не отмечен. Причина отказа в этих записях не определена (4 записи класса L, 4 класса М, 1 класса Н).
2. В 18 записях отмечен подтип RNF при нулевом значении Machine failure. Всего меток RNF в наборе 19, то есть лишь в одном случае случайный отказ отражён в обобщённой метке. Фактически подтип RNF почти не участвует в формировании целевой переменной.

Кроме того, в 24 записях одновременно отмечено более одного подтипа отказа (в 23 случаях два подтипа, в одном случае три). Это не является

ошибкой: одно наблюдение может удовлетворять условиям нескольких механизмов отказа одновременно, однако при построении классификатора типа отказа задачу следует рассматривать как многометочную либо вводить приоритет подтипов.

4.7. Проверка соответствия данных документированным правилам

Ключевая проверка для дальнейшей работы: насколько точно условия возникновения отказов, описанные в документации набора и положенные в основу базы продукционных правил на первом этапе проекта, воспроизводятся на фактических данных. Для проверки рассчитаны производные признаки:

```
df['dT'] = df['Process temperature [K]'] - df['Air temperature [K]']
df['power'] = df['Torque [Nm]'] * df['Rotational speed [rpm]'] * 2*np.pi / 60
df['wt'] = df['Tool wear [min]'] * df['Torque [Nm]']
lim = df['Type'].map({'L': 11000, 'M': 12000, 'H': 13000})

hdf = (df['dT'] < 8.6) & (df['Rotational speed [rpm]'] < 1380)
pwf = (df['power'] < 3500) | (df['power'] > 9000)
osf = df['wt'] > lim
twf = df['Tool wear [min]'].between(200, 240)
```

Результаты сопоставления сформированных по правилам признаков с фактическими метками приведены в таблице 7. Полнота показывает долю фактических отказов данного типа, распознанных правилом; точность - долю действительных отказов среди всех срабатываний правила.

Таблица 7 - Соответствие документированных правил фактическим меткам

Тип отказа	Условие	Сработало записей	Меток в наборе	Совпадений	Полнота %	Точность %
HDF	Разность температур < 8,6 К и обороты < 1380 об/мин	115	115	115	100,0	100,0
PWF	Мощность привода < 3500 Вт или > 9000 Вт	95	95	95	100,0	100,0
OSF	Износ × момент > 11 000 / 12 000 / 13 000 (L / M / H)	98	98	98	100,0	100,0
TWF	Износ инструмента в диапазоне от 200 до 240 мин	790	46	43	93,5	5,4

Правила для нарушения теплоотвода, отказа по мощности и перегрузки воспроизводят метки набора абсолютно точно: полнота и точность равны 100 %. Это принципиально важный результат - он означает, что база производционных правил, сформулированная на первом этапе, не является приблизительной и полностью согласована с данными, а механизм вывода может быть верифицирован на этом наборе строго.

Правило по износу инструмента ведёт себя иначе: при полноте 93,5 % его точность составляет лишь 5,4 %, поскольку условие выполняется для 790 записей, а отказ зафиксирован лишь в 46. Это отражает вероятностную природу данного механизма: отказ инструмента в наборе назначается случайным образом внутри интервала износа от 200 до 240 минут, а не детерминированно. Три записи с меткой TWF имеют износ вне указанного интервала (198, 246 и 253 минуты), что дополнительно подтверждает стохастический характер правила. Практический вывод: правило по износу должно применяться не как жёсткое условие отказа, а как условие повышения оценки риска с коэффициентом уверенности порядка 0,06.

Соотношение фактических данных с пороговыми значениями правил по износу и перегрузке показано на рисунке 7.




Рисунок 7 - Сопоставление данных с пороговыми значениями правил TWF и OSF

Раздел 5. План очистки и трансформации

По результатам анализа выявленные проблемы и планируемые действия сведены в таблицу 8. Классические операции очистки - заполнение пропусков

и удаление дубликатов - не требуются; основной объём подготовки составляют переименование полей, приведение типов, устранение дефектов разметки и формирование производных признаков.

Таблица 8 - Выявленные проблемы и план очистки данных

Поле или аспект	Проблема	Доля	Серьёзность	Решение
Все поля	Пропуски отсутствуют	0 %	Отсутствует	Обработка не требуется; в конвейер добавляется проверка -утверждение на отсутствие пропусков при загрузке новых данных
Все поля	Дубликаты отсутствуют	0 %	Отсутствует	Обработка не требуется
Имена полей	Пробелы и квадратные скобки в именах затрудняют обращение к столбцам	100 %	Низкая	Переименование в snake_case: air_temp_k, process_temp_k, rot_speed_rpm, torque_nm, tool_wear_min
UDI, Product ID	Уникальны для каждой записи, предсказательной ценности не несут	100 %	Низкая	Исключить из анализа; Product ID сохранить как ключ для связи с фреймом изделия
Type	Тип object, избыточный расход памяти	100 %	Низкая	Привести к типу category с упорядочением $L < M < H$
Type	Фактическое соотношение классов 60 / 30 / 10 % против заявленных 50 / 30 / 20 %	-	Низкая	Изменение не вносится; расхождение фиксируется в документации, выводы по классу H сопровождаются оговоркой о малом объёме выборки
Rotational speed, Torque	Статистические выбросы по правилу IQR (418 и 69 записей)	4,18 % и 0,69 %	Средняя	Не удалять: выбросы связаны с отказами (89,9 % записей с аномальным моментом - отказы). Добавить флаги is_outlier_speed, is_outlier_torque
Machine failure	В 9 записях отказ отмечен без указания подтипа	0,09 %	Средняя	Сохранить записи, пометить флагом failure_type_unknown и исключить из обучающей выборки классификатора типа отказа
RNF	В 18 записях из 19 подтип отмечен при нулевой обобщённой метке	0,18 %	Средняя	Исключить RNF из целевой переменной как несогласованный и непредсказуемый по режимам работы; сохранить как справочный признак
TWF, HDF, PWF, OSF	В 24 записях одновременно отмечено несколько подтипов	0,24 %	Низкая	Задача классификации типа отказа рассматривается как многометочная; для одномерной постановки вводится приоритет подтипов по тяжести последствий
Целевая переменная	Дисбаланс классов 3,39 % против 96,61 %	-	Высокая	Стратифицированное разбиение выборки; оценка качества по полноте и точности, а не по доле

Поле или аспект	Проблема	Доля	Серьёзность	Решение
				верных ответов; для правил - подбор порогов по F-мере
Производные признаки	Содержательными являются комбинации признаков, а не отдельные величины	-	Высокая	Рассчитать и сохранить temp_diff_k, power_w, wear_torque, osf_limit, power_margin
Масштаб признаков	Диапазоны признаков различаются на три порядка	-	Средняя	Для производственных правил масштабирование не требуется; для генетического алгоритма нормировать составляющие целевой функции

Последовательность обработки на следующем этапе:

1. загрузка исходного файла с проверкой размерности и отсутствия пропусков;
2. переименование полей и приведение типа поля Type к category;
3. расчёт производных признаков temp_diff_k, power_w, wear_torque и порога перегрузки osf_limit по классу качества;
4. формирование флагов нештатных режимов и флага неопределённого типа отказа;
5. исключение поля RNF из состава целевых переменных;
6. сохранение подготовленного набора в формате CSV и Parquet для дальнейшего использования базой знаний и модулем оптимизации.

Раздел 6. Выводы

В ходе работы выполнен разведочный анализ набора данных AI4I 2020 Predictive Maintenance Dataset, выбранного в качестве основного источника на первом этапе проекта. Набор загружен средствами pandas, проверена его целостность: фактические размерность (10 000 записей, 14 полей) и состав полей полностью соответствуют заявленным в описании источника.

Качество данных оценено как высокое. Пропущенные значения отсутствуют во всех полях, дубликаты не обнаружены ни при полном сравнении строк, ни при сравнении только по показаниям датчиков, противоречий между идентификатором изделия и классом качества нет,

отрицательных и физически невозможных значений не выявлено. Это позволяет исключить из плана подготовки трудоёмкие процедуры восстановления пропусков.

Анализ распределений показал, что температуры и крутящий момент близки к нормальному закону, износ инструмента распределён равномерно, а частота вращения имеет выраженную правостороннюю асимметрию, обусловленную обратной зависимостью от крутящего момента при примерно постоянной мощности привода. Формально выявленные выбросы (418 записей по оборотам и 69 по моменту) удалению не подлежат: они соответствуют предотказным режимам, среди записей с аномальным крутящим моментом доля отказов достигает 89,9 % против 3,39 % в среднем по набору.

Корреляционный анализ выявил две сильные связи - между температурой процесса и температурой воздуха (0,876) и между крутящим моментом и частотой вращения (-0,875). Обе связи имеют технологическую природу и подтверждают, что содержательными для диагностики являются производные величины: разность температур и мощность привода.

Главный результат работы - подтверждение применимости базы продукционных правил, сформулированной на первом этапе. Правила для нарушения теплоотвода, отказа по мощности и перегрузки воспроизводят фактические метки набора с полнотой и точностью 100 %, то есть являются не эвристическими предположениями, а точным описанием механизмов отказа. Правило по износу инструмента при полноте 93,5 % имеет точность 5,4 %, что отражает стохастическую природу этого механизма и требует перевода правила из категории детерминированных в категорию правил с коэффициентом уверенности.

Выявлены три особенности, которые необходимо учесть в дальнейшем: дисбаланс целевого класса (3,39 %), требующий стратифицированного разбиения выборки и оценки качества по полноте и точности; дефекты разметки (9 записей с отказом без указания подтипа и 18 записей с подтипом RNF при нулевой обобщённой метке); расхождение фактического

распределения классов качества (60 / 30 / 10 %) с заявленным в документации (50 / 30 / 20 %).

Сформирован план очистки и трансформации из тринадцати позиций, включающий переименование полей, приведение типов, устранение дефектов разметки и расчёт пяти производных признаков. Подготовленный набор данных пригоден для реализации базы знаний производственной системы, наполнения фреймов оборудования и формирования оценок риска, используемых целевой функцией генетического алгоритма на последующих этапах проекта.

Список использованных источников

1. Маккинни У. Python и анализ данных: первичная обработка данных с применением pandas, NumPy и Jupyter / У. Маккинни ; пер. с англ. - 3-е изд. - Москва : ДМК Пресс, 2023. - 536 с. - ISBN 978-5-93700-174-0.
2. Вандер Плас Дж. Python для сложных задач: наука о данных и машинное обучение / Дж. Вандер Плас ; пер. с англ. - Санкт-Петербург : Питер, 2021. - 576 с. - ISBN 978-5-4461-0914-2.
3. Брюс П. Практическая статистика для специалистов Data Science: 50+ важнейших понятий с использованием R и Python / П. Брюс, Э. Брюс, П. Гедек ; пер. с англ. - 2-е изд. - Санкт-Петербург : БХВ-Петербург, 2021. - ISBN 978-5-9775-6705-3.
4. Tukey J. W. Exploratory Data Analysis / J. W. Tukey. - Reading : Addison-Wesley, 1977. - 688 p. - ISBN 0-201-07616-0.
5. Matzka S. Explainable Artificial Intelligence for Predictive Maintenance Applications / S. Matzka // Third International Conference on Artificial Intelligence for Industries (AI4I). - 2020. - P. 69-74.
6. AI4I 2020 Predictive Maintenance Dataset : [набор данных] // UCI Machine Learning Repository. - URL:

<https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset> (дата обращения: 15.09.2026).

7. pandas documentation : [официальная документация библиотеки]. - URL: <https://pandas.pydata.org/docs/> (дата обращения: 15.09.2026).
8. Matplotlib: Visualization with Python : [официальная документация библиотеки]. - URL: <https://matplotlib.org/stable/index.html> (дата обращения: 15.09.2026).

Приложение А. Листинг программы разведочного анализа

Ниже приведён текст программы, использованной для получения всех приведённых в отчёте числовых результатов.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

NUM = ['Air temperature [K]', 'Process temperature [K]',
       'Rotational speed [rpm]', 'Torque [Nm]', 'Tool wear [min]']
MODES = ['TWF', 'HDF', 'PWF', 'OSF', 'RNF']

df = pd.read_csv('data/ai4i2020.csv', encoding='utf-8-sig')
print('Размерность:', df.shape)
print('Память, КБ: %.1f' % (df.memory_usage(deep=True).sum() / 1024))
print(df.dtypes)
print(df.head())

print('Пропусков всего:', df.isnull().sum().sum())
print(df.isnull().sum())

print('Полных дубликатов:', df.duplicated().sum())
print('Без идентификаторов:', df.drop(columns=['UDI', 'Product ID']).duplicated().sum())
print('Только по датчикам:', df[NUM].duplicated().sum())
print('Соответствие Product ID и Type:', (df['Product ID'].str[0] == df['Type']).sum())

desc = df[NUM].describe().T
desc['median'] = df[NUM].median()
desc['skew'] = df[NUM].skew()
desc['kurtosis'] = df[NUM].kurtosis()
print(desc)

for c in NUM:
    q1, q3 = df[c].quantile(.25), df[c].quantile(.75)
    iqr = q3 - q1
    lo, hi = q1 - 1.5 * iqr, q3 + 1.5 * iqr
    mask = (df[c] < lo) | (df[c] > hi)
    fail = (mask & (df['Machine failure'] == 1)).sum()
    print('%-26s границы [%.2f; %.2f] выбросов %4d (%.2f%%), из них отказов %d'
          % (c, lo, hi, mask.sum(), 100 * mask.mean(), fail))

print(df[NUM].corr(method='pearson').round(3))
print(df[NUM].corr(method='spearman').round(3))

print(df['Type'].value_counts())
print((100 * df['Type'].value_counts(normalize=True)).round(2))
for c in ['Machine failure'] + MODES:
    print('%-16s %4d (%.2f%%)' % (c, df[c].sum(), 100 * df[c].mean()))
print(pd.crosstab(df['Type'], df['Machine failure'], normalize='index').round(4) * 100)
print(df.groupby('Type')[MODES].sum())

sub = df[MODES].sum(axis=1)
print('Отказ без подтипа:', ((df['Machine failure'] == 1) & (sub == 0)).sum())
print('Подтип без отказа:', ((df['Machine failure'] == 0) & (sub > 0)).sum())
print('Несколько подтипов:', (sub > 1).sum())

df['dT'] = df['Process temperature [K]'] - df['Air temperature [K]']
df['power'] = df['Torque [Nm]'] * df['Rotational speed [rpm]'] * 2 * np.pi / 60
df['wt'] = df['Tool wear [min]'] * df['Torque [Nm]']
lim = df['Type'].map({'L': 11000, 'M': 12000, 'H': 13000})

rules = {
    'HDF': (df['dT'] < 8.6) & (df['Rotational speed [rpm]'] < 1380),
    'PWF': (df['power'] < 3500) | (df['power'] > 9000),
    'OSF': df['wt'] > lim,
```

```

    'TWF': df['Tool wear [min]'].between(200, 240),
}
for name, mask in rules.items():
    flag = df[name] == 1
    both = (mask & flag).sum()
    print('%s: срабатываний %4d, меток %3d, совпадений %3d, '
          'полнота %.1f%%, точность %.1f%%'
          % (name, mask.sum(), flag.sum(), both,
             100 * both / flag.sum(), 100 * both / mask.sum()))

fig, ax = plt.subplots(2, 3, figsize=(12, 6))
for i, c in enumerate(NUM + ['power']):
    a = ax[i // 3][i % 3]
    a.hist(df[c], bins=40, color='0.72', edgecolor='black', linewidth=0.4)
    a.axvline(df[c].mean(), color='black')
    a.axvline(df[c].median(), color='black', ls='--')
    a.set_title(c)
plt.tight_layout()
plt.savefig('img/hist.png', dpi=200)

fig, ax = plt.subplots(1, 5, figsize=(12, 4))
for i, c in enumerate(NUM):
    ax[i].boxplot(df[c], widths=0.55)
    ax[i].set_title(c)
plt.tight_layout()
plt.savefig('img/box.png', dpi=200)

fig, a = plt.subplots(figsize=(5, 4.5))
C = df[NUM].corr().values
a.imshow(np.abs(C), cmap='Greys', vmin=0, vmax=1)
for i in range(5):
    for j in range(5):
        a.text(j, i, '%.2f' % C[i, j], ha='center', va='center')
plt.tight_layout()
plt.savefig('img/corr.png', dpi=200)

df.to_csv('data/ai4i_derived.csv', index=False)

```