

Занятие 3

Проектирование ETL/ELT процесса

3.1. Цели и задачи работы

Цель работы: на основе проведённого EDA спроектировать процесс ETL/ELT для очистки и преобразования данных, подготовить схему потока данных и определить необходимые трансформации.

Задачи работы:

1. Проанализировать результаты EDA и составить спецификацию требований к очистке данных.
2. Выбрать стратегию ETL или ELT для своего проекта.
3. Спроектировать пайплайн обработки данных в виде диаграммы.
4. Определить необходимые трансформации для каждого поля.
5. Оформить техническую документацию ETL-процесса.

3.2. Теоретические сведения

3.2.1. Понятие ETL и ELT

ETL (Extract, Transform, Load) — процесс, в котором данные извлекаются из источника, преобразуются в промежуточном хранилище, а затем загружаются в целевое хранилище.

ELT (Extract, Load, Transform) — процесс, в котором данные сначала загружаются в хранилище, а затем преобразуются уже внутри него (часто используется в современных облачных решениях).

ETL: Источник → Извлечение → Трансформация → Загрузка → Хранилище
ELT: Источник → Извлечение → Загрузка → Трансформация → Хранилище

3.2.2. Основные этапы ETL-процесса

Этап	Описание	Действия
Extract (Извлечение)	Получение данных из источника	Чтение файлов, запросы к API, выгрузка из БД
Transform (Преобразование)	Очистка и нормализация	Удаление дубликатов, заполнение пропусков, приведение типов
Load (Загрузка)	Помещение данных в хранилище	Вставка в таблицы, обновление, мерж

3.2.3. Типы трансформаций данных

Тип трансформации	Описание	Пример
Очистка	Удаление или исправление некорректных данных	Удаление строк с отрицательным возрастом

Заполнение пропусков	Обработка missing values	Заполнение медианой, средним, модой
Нормализация	Приведение к единому формату	Приведение дат к единому формату
Удаление дубликатов	Устранение повторяющихся записей	df.drop_duplicates()
Создание новых признаков	Генерация производных полей	Возраст из даты рождения
Агрегация	Группировка данных	Сумма продаж по месяцам
Фильтрация	Отбор нужных записей	Только завершённые заказы

3.2.4. Инструменты для проектирования ETL

- **Draw.io** — бесплатный онлайн-редактор диаграмм
- **Lucidchart** — более продвинутый инструмент (есть бесплатная версия)
- **Microsoft Visio** — (если доступен)

3.3. Порядок выполнения работы

Шаг 1. Анализ результатов EDA

На основе отчёта по занятию №2 составьте таблицу проблем и требуемых трансформаций:

Таблица 3.1 — Спецификация трансформаций

Поле	Текущий тип	Целевой тип	Проблема	Трансформация	Примечание
film_id	int	int	Дублирующиеся записи (~2.5%)	Дедупликация: оставить первую запись по film_id, остальные удалить	Выполнять первым шагом до любых других трансформаций
budget	float / null	float	Пропуски ~14% (MNAR)	1. Создать флаг budget_missing (bool). 2. Заполнить медианой по жанру (genre)	Не использовать глобальную медиану — бюджет сильно зависит от жанра
budget	float	float	Выбросы: правый хвост (блокбастеры > 95-го перцентиля)	Winsorize до P95 для перрессионных задач; создать флаг is_blockbuster	Оригинальные значения сохранить в budget_raw
.....					

Порядок применения трансформаций имеет значение: дедупликация → проверка диапазонов и флаги аномалий → заполнение пропусков → маппинг категорий → создание производных признаков (log_budget, roi) → кодирование категорий. Нарушение порядка — например, заполнение пропусков до дедупликации — может привести к тому, что восстановленные значения будут усреднять данные дублирующихся записей, внося систематическое смещение.

Шаг 2. Выбор стратегии ETL или ELT

Определите, какой подход больше подходит для вашего проекта:

Сделайте выбор и обоснуйте его.

Выбор стратегии ETL vs ELT — сравнительная таблица

Критерий	ETL	ELT	Оценка для проекта	Выбор
Объём данных	Малый и средний	Большой	IMDb TSV — ~10 млн строк, 3 источника с разными схемами. Объём средний, MPP-хранилище не требуется	ETL
Сложность трансформаций	Высокая	Средняя	12 операций из спецификации: Winsorize, log1p, дедупликация, маппинг age_rating, ROI, условное заполнение пропусков. Логика сложная — удобнее в Python/pandas до загрузки	ETL
Требования к скорости загрузки	Критичны	Не критичны	Данные о фильмах и сборах обновляются раз в сутки (IMDb) или реже. Скорость загрузки не критична	Нейтрально
Мощность хранилища	Ограничена	Высокая	Данные о фильмах и сборах обновляются раз в сутки (IMDb) или реже. Скорость загрузки не критична	ETL

Обоснование в одной строке на каждый аргумент.

Трансформации сложны — их логичнее держать в Python-коде, а не в SQL хранилища.

Хранилище слабее источника — нагружать PostgreSQL вычислениями нецелесообразно.

Источники разнородны — объединение через pandas проще, чем staging + dbt.

Объём средний — облачный MPP избыточен.


Pipeline тестируем — pytest-покрытие на трансформациях проще, чем на SQL-моделях.


Шаг 3. Проектирование пайплайна

Создайте диаграмму ETL-процесса, включающую:


1. **Источники данных** (файлы, API, БД)
2. **Этапы извлечения** (какие данные откуда берутся)
3. **Этапы трансформации** (последовательность преобразований)
4. **Промежуточные хранилища** (staging area)
5. **Целевое хранилище** (структура таблиц)

Пример структуры пайплайна:





Детальная схема Transform-слоя



Шаг 4. Описание трансформаций

Для каждого поля подробно опишите, какие преобразования будут выполнены:

Пример описания трансформации для поля `release_date`:

```
Поле: release_date
Текущий тип: object (строка)
Проблема: встречаются форматы "YYYY-MM-DD", "DD.MM.YYYY", "YYYY"
Целевой тип: datetime

Алгоритм трансформации:
1. Попыаться распарсить как "YYYY-MM-DD" (основной формат)
2. Если не получилось, попробовать "DD.MM.YYYY"
3. Если не получилось, для значений только с годом установить "YYYY-01-01"
4. Если парсинг не удался — установить NaT
5. Удалить строки с NaT, если их доля < 1%, иначе заполнить медианной датой
```

Шаг 5. Оформление отчёта

3.4. Структура отчёта

Раздел 1. Цель работы

Раздел 2. Анализ требований к очистке данных

- Спецификация трансформаций (таблица 3.1)

Раздел 3. Выбор стратегии ETL/ELT

- Обоснование выбора

Раздел 4. Схема ETL-процесса

- Диаграмма потока данных
- Описание каждого этапа

Раздел 5. Детальное описание трансформаций

- По полям с примерами

Раздел 6. Выводы

3.5. Контрольные вопросы

1. В чём принципиальное отличие ETL от ELT?
2. Для каких задач предпочтительнее использовать ETL, а для каких — ELT?
3. Что такое staging area и зачем она нужна?
4. Какие существуют стратегии обработки пропусков?
5. Как обеспечить идемпотентность ETL-процесса?

3.6. Литература

1. DAMA International. DAMA-DMBOK: Свод знаний по управлению данными / пер. с англ. Г. Агафоновой. — 2-е изд. — М. : Олимп-Бизнес, 2020. — 828 с. — ISBN 978-5-9693-0404-8. Раздел «Интеграция и взаимодействие данных» напрямую про проектирование ETL/ELT.
2. Кимбалл, Р. Инструментарий хранения и анализа данных. Полное руководство по размерному моделированию / Р. Кимбалл, М. Росс ; пер. с англ. — М. : Эксмо. — ISBN 978-5-04-108040-2. Содержит главу о подсистемах ETL как части архитектуры хранилища.