

Занятие 5

Проектирование хранилища данных

5.1. Цели и задачи работы

Цель работы: спроектировать структуру хранилища данных для дальнейшего использования в задачах ИИ, выбрать модель данных и создать схему базы данных.

Задачи работы:

1. Проанализировать очищенные данные и определить требования к хранилищу.
2. Выбрать модель данных (звезда, снежинка, нормализованная).
3. Выделить таблицы фактов и измерений.
4. Разработать ER-диаграмму хранилища.
5. Создать SQL-скрипты для создания таблиц.

5.2. Теоретические сведения

5.2.1. Понятие хранилища данных (Data Warehouse)

Хранилище данных (Data Warehouse, DWH) — это предметно-ориентированная, интегрированная, неизменяемая и поддерживающая хронологию совокупность данных, организованная для поддержки принятия решений.

Основные свойства DWH:

- **Предметная ориентация** — данные организованы по темам, а не по приложениям
- **Интегрированность** — данные из разных источников приведены к единому формату
- **Неизменность** — данные не обновляются, только добавляются
- **Поддержка хронологии** — хранятся исторические данные

5.2.2. Модели данных для хранилищ

Схема	Описание	Когда применять
Звезда (Star Schema)	Одна таблица фактов в центре, окружена таблицами измерений напрямую	Простые аналитические запросы, небольшой объем
Снежинка (Snowflake Schema)	Таблицы измерений нормализованы, образуют иерархии	Экономия места, сложные измерения
Нормализованная	Классическая 3NF-структура	Оперативные системы, частые обновления

5.2.3. Таблицы фактов и измерений

Таблица фактов — содержит числовые метрики (факты) и ключи к таблицам измерений. Обычно очень большая по количеству строк.

Таблицы измерений — содержат описательные атрибуты (кто, что, где, когда). Относительно небольшие.

Пример для предметной области «Кинопрокат»:

Таблица	Тип	Ключевые поля
fact_rating	Факты	rating_id, movie_id, user_id, date_id, rating, votes
dim_movie	Измерение	movie_id, title, genre, director, release_year, budget
dim_user	Измерение	user_id, age_group, country, registration_date
dim_date	Измерение	date_id, date, year, month, quarter, day_of_week

Таблица фактов обычно содержит:

- Внешние ключи на таблицы измерений
- Числовые показатели (metrics)
- Дату/время события

Таблица измерений обычно содержит:

- Суррогатный ключ (id)
- Бизнес-ключ (natural key)
- Описательные атрибуты

5.3. Порядок выполнения работы

Шаг 1. Анализ очищенных данных

Загрузите очищенные данные и проанализируйте их структуру:

```
import pandas as pd
df = pd.read_csv('data_cleaned.csv')
print(f"Всего записей: {len(df)}")
print(f"Поля: {df.columns.tolist()}")
df.head()
```

Определите, какие поля являются:

- **Показателями (мерами)** — числовые значения, которые можно агрегировать (суммы, количества)
- **Атрибутами** — описательные характеристики
- **Ключами** — идентификаторы объектов

Шаг 2. Выделение таблицы фактов

Определите, что будет таблицей фактов. Обычно это центральное событие в предметной области.

Пример для разных вариантов:

Вариант	Таблица фактов	Описание
Кинопрокат	fact_ratings	Оценки фильмов пользователями

Розничная торговля	fact_sales	Продажи товаров
Медицина	fact_visits	Посещения врача/диагнозы
Библиотека	fact_citations	Цитирования статей

Заполните структуру таблицы фактов:

```
fact_table = {
    'name': 'fact_...',
    'description': '...',
    'measures': ['поле1', 'поле2'],      # числовые показатели
    'dimension_keys': ['поле3', 'поле4'] # внешние ключи
}
```

Шаг 3. Выделение таблиц измерений

Для каждого ключа в таблице фактов определите таблицу измерений:

Таблицы измерений

Измерение	Описание	Атрибуты	Источник данных
dim_...	...	поле1, поле2	из каких полей df
dim_...	...	поле1, поле2	из каких полей df

Шаг 4. Выбор схемы данных

Обоснуйте выбор схемы:

- Если выбрали «звезду» — почему денормализация оправдана?
- Если выбрали «снежинку» — почему важна нормализация?
- Если выбрали другую модель — обоснуйте

Шаг 5. Создание ER-диаграммы

Создайте ER-диаграмму с помощью draw.io или аналогичного инструмента. Диаграмма должна включать:

- Все таблицы с названиями
- Поля таблиц (ключевые помечены)
- Связи между таблицами (1:M, M:M)

Шаг 6. Написание SQL-скриптов

Создайте SQL-скрипт для создания таблиц:

5.4. Структура отчёта

Раздел 1. Цель работы

Раздел 2. Анализ структуры данных

- Описание полей с указанием роли (мера/атрибут/ключ)

Раздел 3. Проектирование хранилища

- 3.1. Таблица фактов (описание, меры)
- 3.2. Таблицы измерений (описание, атрибуты)
- 3.3. Обоснование выбора схемы данных

Раздел 4. ER-диаграмма

- Изображение диаграммы
- Описание связей

Раздел 5. SQL-скрипты

- Код создания таблиц

Раздел 6. Выводы

5.5. Контрольные вопросы

1. В чём разница между таблицей фактов и таблицей измерений?
2. Какие преимущества даёт схема «звезда» перед нормализованной схемой?
3. Что такое суррогатный ключ и зачем он нужен?
4. Как обеспечить целостность данных в хранилище?
1. Какие типы связей между таблицами возможны в хранилище?

5.6. Литература

1. Кимбалл, Р. Инструментарий хранения и анализа данных. Полное руководство по размерному моделированию / Р. Кимбалл, М. Росс ; пер. с англ. — М. : Эксмо. — ISBN 978-5-04-108040-2. Главный первоисточник по размерному моделированию (звезда/снежинка, факты/измерения).
2. Хранилища данных. Обзор технологий и подходов к проектированию // Хабр. URL: <https://habr.com/ru/articles/822669/> (дата обращения: 10.07.2026). Сравнение методологий Кимбалла и Инмона.
3. Теория и практика DWH: что такое согласованные факты и измерения по Кимбаллу // Хабр. URL: <https://habr.com/ru/articles/1052842/> (дата обращения: 10.07.2026). Разбор согласованных измерений/фактов.
4. Обзор гибких методологий проектирования DWH // Хабр. URL: <https://habr.com/ru/companies/glowbyte/articles/515940/> (дата обращения: 10.07.2026). Agile-подходы к проектированию хранилищ.
5. Архитектура хранилищ данных: традиционная и облачная // Хабр. URL: <https://habr.com/ru/articles/441538/> (дата обращения: 10.07.2026). Сравнение классической и облачной архитектур.